

EDUARDO JOSÉ DA SILVA LUZ

Orientador: David Menotti Gomes

**CLASSIFICAÇÃO AUTOMÁTICA DE ARRITMIAS:  
UM NOVO MÉTODO USANDO CLASSIFICAÇÃO  
HIERÁRQUICA**

Ouro Preto  
Fevereiro de 2012

UNIVERSIDADE FEDERAL DE OURO PRETO  
INSTITUTO DE CIÊNCIAS EXATAS E BIOLÓGICAS  
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

**CLASSIFICAÇÃO AUTOMÁTICA DE ARRITMIAS:  
UM NOVO MÉTODO USANDO CLASSIFICAÇÃO  
HIERÁRQUICA**

Dissertação apresentada ao Curso de Pós-Graduação em Ciência da Computação da Universidade Federal de Ouro Preto como requisito parcial para a obtenção do grau de Mestre em Ciência da Computação.

EDUARDO JOSÉ DA SILVA LUZ

Ouro Preto  
Fevereiro de 2012



UNIVERSIDADE FEDERAL DE OURO PRETO

FOLHA DE APROVAÇÃO

Classificação Automática de Arritmias:  
Um novo método usando Classificação Hierárquica

EDUARDO JOSÉ DA SILVA LUZ

Dissertação defendida e aprovada pela banca examinadora constituída por:

Dr. DAVID MENOTTI GOMES – Orientador  
Universidade Federal de Ouro Preto

Dr. GUILLERMO CÁMARA CHÁVEZ  
Universidade Federal de Ouro Preto

Dr. LUIZ HENRIQUE DE CAMPOS MERSCHMANN  
Universidade Federal de Ouro Preto

Dr. RICARDO DA SILVA TORRES  
Universidade Estadual de Campinas

Ouro Preto, Fevereiro de 2012

# Resumo

De acordo com a organização Mundial de Saúde (OMS), doenças cardíacas são a principal causa de morte no planeta. Todavia, a maioria das doenças cardíacas podem ser diagnosticadas e tratadas com antecedência, com o auxílio de exames preventivos. O exame mais utilizado para diagnóstico de doenças cardíacas é chamado Eletrocardiograma (ECG) que podem identificar as arritmias. As arritmias podem se encaixar em duas categorias, arritmias formadas por um único batimento cardíaco irregular ou como um conjunto irregular de batimentos. As arritmias podem ser raras e inofensivas, mas também podem levar à morte rapidamente. Mais efetivo será seu tratamento, quando detectadas o quanto antes.

Este trabalho apresenta duas contribuições principais: Primeiro, foi elaborada uma revisão da literatura dos métodos destinados à classificação de arritmias em sinais de ECG e segundo, foi proposto um novo método para classificação de arritmias usando classificação hierárquica. Como contribuições secundárias, investigaram-se novas características para representação do batimento cardíaco baseadas em uma representação 2D do sinal de ECG, o Vectorcardiograma (VCG), e redes complexas. Além disso, investigou-se o uso de uma abordagem *wrapper* para seleção de características com análise de sensibilidade neste contexto.

Os resultados obtidos por este novo método usando classificação hierárquica são comparáveis aos resultados reportados por métodos estado-da-arte. As novas características propostas se mostraram eficientes para discriminação da classe SVEB, que é uma das classes minoritárias. A Classificação Hierárquica se mostrou promissora para o problema de classificação de arritmias e a técnica deve ser explorada por pesquisas futuras.

**Palavras-chave:** Arritmia, Eletrocardiograma (ECG), Classificação Hierárquica.

# Abstract

According to World Health Organization (WHO), heart disease is the leading cause of death on the planet. However, most heart disease can be diagnosed and treated in advance with the aid of preventive exams. The most frequently exam to diagnose heart disease is called the electrocardiogram (ECG). Arrhythmias are one sort of heart disease that can be diagnosed with ECG. Arrhythmias can be of two categories, one consisting of one irregular heart beat and another consisting of a set of irregular heartbeats. Arrhythmias can be rare and harmless but can lead to death and should be detected as soon as possible.

This study has two objectives. First, we present a literature review of methods aiming at automatic arrhythmias classification on ECG signals, and second, we propose a new method based on hierarchical classification. As a secondary objective, we investigate new features to represent the heartbeat, based on a 2D representation of the ECG signal, the vectorcardiogram (VCG), and complex networks. We also present the use of a wrapper approach for feature selection using sensitivity analysis in this context.

The results obtained in this work are comparable to results reported by state-of-the-art methods. The new proposed features proved effectiveness for discrimination of the supra-ventricular ectopic beat (SVEB) class, which is one of the minority class. The hierarchical classification has shown considerable effective for the problem of classification of arrhythmias and the technique should be explored by future research.

**Keywords:** Arrhythmia, Electrocardiogram (ECG), Hierarchical Classification.

*Este trabalho é dedicado à Paula, pois sem seu incentivo, ele não teria acontecido.*

# Agradecimentos

Agradeço primeiramente a Deus, pela oportunidade de aprendizado.

A meu orientador, David, por ter aceitado o desafio e acreditado em meu potencial desde o início.

À minha amada esposa Paula, por me dar forças para seguir em frente.

A meus pais, Carlos e Eliane, pelo carinho e apoio em todos os momentos.

A meus queridos irmãos, Paulo, Luiz e Daniel por deixarem minha vida mais feliz.

Aos colegas da Omnimed pelo suporte e inspiração.

E por fim, aos professores Ricardo, Guillermo e Luiz, por gentilmente aceitarem ser os examinadores desta dissertação.

# Sumário

<b>1</b>	<b>Introdução</b>	<b>1</b>
<b>2</b>	<b>Fundamentação Teórica Básica Sobre Classificação de Arritmias</b>	<b>7</b>
2.1	A norma da <i>Association for the Advancement of Medical Instrumentation</i> (AAMI)	7
2.2	MIT-BIH . . . . .	10
2.3	O problema da escolha dos batimentos para avaliação dos métodos . . . . .	12
2.4	Classificação plana <i>versus</i> Classificação hierárquica . . . . .	15
2.4.1	Classificação hierárquica . . . . .	15
<b>3</b>	<b>Revisão da Literatura</b>	<b>18</b>
3.1	Pré-processamento . . . . .	18
3.2	Segmentação . . . . .	19
3.3	Extração de Características . . . . .	21
3.3.1	Redução de Características . . . . .	25
3.3.2	Vectorcardiograma . . . . .	26
3.3.3	Seleção de Características . . . . .	26
3.4	Classificação . . . . .	27
3.4.1	SVM . . . . .	28
3.4.2	ANN . . . . .	29
3.4.3	Discriminantes Lineares . . . . .	30
3.4.4	Considerações Finais . . . . .	30
<b>4</b>	<b>Um novo método para classificação de Arritmias</b>	<b>31</b>
4.1	Segmentação . . . . .	32
4.2	Extração de características . . . . .	33
4.2.1	Vectorcardiograma e Redes Complexas . . . . .	33
4.2.2	Intervalo RR relativo e largura do complexo QRS relativo . . . . .	38
4.2.3	Variância da função de autocorrelação . . . . .	39
4.2.4	O vetor de características . . . . .	39
4.3	Classificação . . . . .	40



4.4	Seleção de Características . . . . .	41
<b>5</b>	<b>Resultados Experimentais</b>	<b>44</b>
5.1	Características da base de dados . . . . .	44
5.2	Experimentos . . . . .	45
5.2.1	Parâmetros para extração de características com VCG e redes complexas	45
5.2.2	Escolha do melhor modelo . . . . .	48
5.2.3	Análise dos modelos . . . . .	49
5.2.4	Teste em DS2 . . . . .	51
5.3	Protocolo AAMI2 . . . . .	52
5.3.1	Modelos de Classificação para AAMI2 . . . . .	52
5.3.2	Melhor modelo AAMI2 . . . . .	53
5.3.3	Teste com AAMI2 . . . . .	54
<b>6</b>	<b>Considerações Finais</b>	<b>56</b>
	<b>Referências Bibliográficas</b>	<b>59</b>

# Lista de Figuras

1.1	Esquema simplificado de um <i>hardware</i> para aquisição de ECG com isolamento, filtros passa-altas (P.A.) e -baixas (P.B.), amplificadores e conversores analógico-digital Figura adaptada de (Clifford et al., 2006).	2
1.2	Configuração com 12 eletrodos.	2
1.3	Morfologia da curva formada pelas derivações I, II e III.	3
1.4	Batimento normal de ECG, derivação II. Figura extraída de (Clifford et al., 2006).	3
1.5	Um diagrama de um sistema de classificação de arritmias.	4
2.1	Exemplo de anotação do banco de dados do MIT-BIH.	8
2.2	Exemplo de uma configuração hierárquica com dez classes.	15
2.3	Esquema de níveis de classificação hierárquicos: Nível 1 - Normal/Arritmia, Nível 2 - S, V, F e Q.	16
3.1	Pontos fiduciais e vários intervalos usuais de um batimento cardíaco. Fonte (Clifford et al., 2006).	22
3.2	Sinal de ECG extraído do MIT-BIH AR DB, amostrado a 360Hz.	23
3.3	Redução do número de características por meio de interpolação. Fonte (de Chazal et al., 2004).	24
3.4	VCG construído a partir de batimentos do registro 202 do MIT-BIH. Figura adaptada de (Llamedo e Martínez, 2011).	26
4.1	Segmento de um batimento normal do registro 100 do MIT-BIH.	32
4.2	Três níveis da transformada wavelet.	33
4.3	Ilustração do processo decomposição. Na primeira linha o sinal original do ECG, na segunda os coeficientes wavelets de aproximação do 1º. nível, e na terceira linha o VCG, para duas classes de batimentos: N e SVEB.	34

# Lista de Tabelas

2.1	Principais tipos de batimentos presentes no banco de dados do MIT-BIH. . . . .	9
2.2	Cálculo de avaliação dos métodos a partir de matrizes de confusão. Fonte (de Chazal et al., 2004). . . . .	10
2.3	Exemplo de exibição de resultados, segundo a norma AAMI. . . . .	10
2.4	Divisão de tipos de batimento no banco de dados do MIT-BIH. . . . .	11
2.5	Distribuição de batimentos por classes dos conjuntos/partições propostos por de Chazal et al. (2004) . . . . .	12
2.6	Lista de trabalhos agrupados de acordo com esquemas utilizados para treinamento e teste dos métodos. # Métodos que seguem a norma sugerida pela AAMI. * Métodos que necessitam de treinamento com batimentos do paciente a ser analisado, chamados adaptativos (classificação semi-automática). . . . .	13
2.7	Resultados obtidos pelos métodos considerando-se conjunto de dados aleatórios para treino e teste com a base de dados de arritmia do MIT-BIH. . . . .	14
2.8	Resultados obtidos pelos métodos segundo esquema de divisão de registros proposto por de Chazal et al. (2004) com a base de dados de arritmia do MIT-BIH. . . . .	14
3.1	Algoritmos para segmentação do batimentos cardíaco. . . . .	21
3.2	Atributos típicos de um sinal de ECG normal, com frequência cardíaca de 60 bpm (batidas por minutos) de um adulto saudável e derivação II. Fonte (Clifford et al., 2006). . . . .	22
5.1	Distribuição de batimentos por registro da base de dados MIT-BIH (Massachusetts Institute of Technology, 2011). Os registros selecionados por de Chazal et al. (2004) como sendo DS1 estão em <b>negrito</b> . . . . .	46
5.2	Avaliação de parâmetros para extração de características de redes complexas a partir do VCG usando os coeficientes Wavelet A1 e D1 e validação cruzada 22- <i>folds</i> em DS1. O valor de $T_0$ é igual a 0,05 para todos os casos. <i>Acc1</i> e <i>Acc2</i> são as acurácias de classificação no primeiro e segundo níveis, respectivamente. . . . .	47
5.3	Desempenho dos modelos plano e hierárquico em DS1 usando 26 características e validação cruzada 22- <i>folds</i> (pacientes/registros). . . . .	49

5.4	Características selecionadas para 3 modelos: Modelo de classificação plana (Plano), primeiro nível hierárquico (Hierárquico 1) e segundo nível hierárquico (Hierárquico 2). Observe que os dados referente as 26 características estão separados em duas subtabelas por motivo de espaço. $CN(VCG(WT - A1))$ está para modelagem de redes complexas obtidas a partir do VCG que por sua vez foi obtido a partir dos coeficientes Wavelet de aproximação do primeiro nível de decomposição, bem como $var(AC(x))$ está para a variância dos coeficientes de auto-correlação do sinal original do ECG. . . . .	50
5.5	Desempenho dos modelos variando o conjunto de características: total (26 características) e seleção de características (SC). . . . .	50
5.6	Resultado final em DS2. $FPR$ não é reportado pelos outros métodos. . . . .	51
5.7	Resultado por paciente em DS2. O modelo utilizado foi o hierárquico com seleção de características independente para cada classificador. . . . .	52
5.8	Desempenho dos modelos em DS1 - validação cruzada por paciente 22-folds. Protocolo AAMI2. . . . .	53
5.9	Características selecionadas para 3 modelos: Modelo de classificação plana (Plano), primeiro nível hierárquico (Hierárquico 1) e segundo nível hierárquico (Hierárquico 2). Protocolo AAMI2. . . . .	53
5.10	Desempenho dos modelos variando o conjunto de características: total (26 características) e seleção de características (SC). Protocolo AAMI2. . . . .	54
5.11	Resultado final em DS2. Protocolo AAMI2. . . . .	54
5.12	Resultado por paciente em DS2. O modelo utilizado foi o hierárquico com seleção de características independente para cada classificador. Protocolo AAMI2 . . . . .	55

# Lista de Algoritmos

4.1 Algoritmo de sensibilidade e busca para frente . . . . . 43

# Capítulo 1

## Introdução

De acordo com a Organização Mundial de Saúde (OMS), doenças cardíacas são a principal causa de morte no planeta. E apesar de boa parte das doenças cardíacas poderem ser diagnosticadas com antecedência, o número de casos continuam a crescer muito. Estima-se que 80% dos casos aconteçam em países pobres e em desenvolvimento e, segundo a OMS, até o ano de 2030 (World Health Organization, 2012), 23,6 milhões de pessoas vão morrer por cause de doenças cardíacas, pois as medidas de prevenção, aparentemente, não estão sendo adequadas.

O principal exame para diagnóstico de doenças cardíacas é chamado Eletrocardiograma (ECG). Segundo Cohen (1988), o ECG foi um dos primeiros sinais estudados pelas técnicas de processamento de sinais biomédicos e até os dias de hoje é a técnica mais utilizada no diagnóstico de doenças do coração. Isto se deve à simplicidade do exame, que é um processo não-invasivo.

O coração é um músculo que se contrai de forma rítmica, bombeando o sangue pelo corpo. Essa contração tem início no nodo sino atrial, que age como um marca-passo natural, e se propaga para o restante do músculo. A propagação elétrica do sinal no coração segue um padrão, coordenado por sua contração. Como resultado desta atividade elétrica, correntes elétricas são geradas na superfície do corpo provocando variações no potencial elétrico da superfície da pele, que podem ser adquiridas ou mensuradas com o auxílio de eletrodos e um equipamento apropriado.

Uma ilustração de tal equipamento é apresentada na Figura 1.1, e seu funcionamento brevemente discutido a seguir. A diferença de potencial entre os pontos marcados pelos eletrodos na pele usualmente é realçada com o auxílio de amplificador instrumental com isolamento ótica. Em seguida, o sinal é submetido a: um filtro passa-altas; um segundo estágio de amplificação; a um filtro de *antialiasing* passa-baixas; e, por fim, é amostrado por um conversor analógico-digital (ADC). O registro gráfico desta aquisição é chamado ECG.

Três ou mais eletrodos são utilizados para obtenção do sinal, sendo que um deles deve ser aterrado e servir de referência aos demais. Normalmente, aterra-se o eletrodo posicionado próximo à perna direita (RL - Do inglês *Right Leg*). Assim, podem-se ter “visões” diferentes




Figura 1.1: Esquema simplificado de um *hardware* para aquisição de ECG com isolamento, filtros passa-altas (P.A.) e -baixas (P.B.), amplificadores e conversores analógico-digital  
Figura adaptada de (Clifford et al., 2006).

do sinal de ECG dependendo dos pares de eletrodos escolhidos para a construção do sinal. A essas diferentes visões dá-se o nome de derivação.

Uma configuração de eletrodos muito utilizada é composta por cinco eletrodos, dos quais um eletrodo é posicionado no braço esquerdo (LA - do inglês *left arm*), um no braço direito (RA - *right arm*), um na perna esquerda (LL - *left leg*), um na perna direita (RL - *right Leg*) e um no peito, à direita do esterno (V ou V1). Outra configuração muito utilizada é composta por doze eletrodos, como pode ser visto na Figura 1.2.




Figura 1.2: Configuração com 12 eletrodos.

A partir dessas configurações, podem-se construir diferentes derivações para a visualização do sinal de ECG. Por exemplo, a Figura 1.3 ilustra 3 derivações: derivação I, formada pela diferença entre o potencial elétrico dos eletrodos LA e RA; derivação II, formada pela diferença entre o potencial elétrico nos eletrodos LL e RA; e a derivação III, formada pela diferença entre o potencial elétrico nos eletrodos LL e LA.

A derivação II (LL e RA) é a mais utilizada para o diagnóstico de doenças cardíacas. Ela acentua diversos segmentos dentro de um batimento cardíaco, além das três ondas mais importantes, as ondas P, QRS e T, como ilustrado na Figura 1.4. Estas ondas correspondem ao campo induzido pelos fenômenos elétricos na superfície cardíaca, denominados despolarização atrial (onda P), despolarização ventricular (complexo QRS) e repolarização ventricular (onda T).




Figura 1.3: Morfologia da curva formada pelas derivações I, II e III.




Figura 1.4: Batimento normal de ECG, derivação II. Figura extraída de (Clifford et al., 2006).

Um dos problemas cardíacos detectável pelo exame de ECG são as arritmias. Arritmias são batimentos cardíacos anormais ou irregulares. Têm-se duas categorias de arritmias. Arritmias formadas por um único batimento cardíaco irregular, neste trabalho chamada de arritmias morfológicas, ou como um conjunto irregular de batimentos, denominadas arritmias rítmicas. As arritmias podem ser esporádicas e inofensivas ou podem indicar um problema cardíaco sério. Portanto, devem ser identificadas e classificadas o quanto antes.

Existem vários tipos de arritmias, dentro das duas categorias já mencionadas, e elas podem ser identificados pelo ECG. Em ambos os casos, as arritmias são caracterizadas por produzirem alterações na morfologia da onda formando assim um padrão. Este padrão é associado a cada tipo de arritmia e, assim, um ser humano é capaz de identificar os padrões e classificar os tipos de arritmias.

Entretanto, o processo de identificação e classificação de arritmias pode ser muito penoso para um ser humano e, ainda sujeito a erros, visto que seria necessário uma análise de bati-



mento a batimento em horas ou até mesmo dias de registros de ECG capturados, por exemplo por um *holter* cardíaco. Uma alternativa consiste no uso de técnicas para classificação automática.




Figura 1.5: Um diagrama de um sistema de classificação de arritmias.

Um sistema completo para automatização da classificação de arritmias no sinal de ECG pode ser dividido em quatro etapas subsequentes (ver Figura 1.5): pré-processamento, segmentação, extração de características e classificação. Em cada uma das quatro etapas uma ação é tomada e o objetivo final é a discriminação do tipo do batimento cardíaco.

As duas primeiras etapas do sistema de classificação (pré-processamento e segmentação) foram amplamente exploradas na literatura (Sayadi e Shamsollahi, 2007, 2008; Martinez et al., 2004; Li et al., 1995; Bahoura et al., 2007). Em particular, os resultados alcançados na etapa de segmentação se aproximam muito da otimalidade, *i.e.*, conseguem dividir, separar e determinar a duração de cada batimento do paciente sem erro algum. Já o pré-processamento depende de vários outros fatores que influenciam diretamente o resultado final. E não é trivial avaliar o impacto do pré-processamento na classificação final, de uma forma geral. Entretanto, etapas relacionadas à classificação, ou seja, extração de características e aprendizado de máquinas, ainda têm muita margem para investigação. Esta dissertação foca exatamente nessas duas últimas etapas.

Visando normatizar o processo de classificação de arritmias em ECG, a Associação para o Avanço da Instrumentação Médica (sigla em inglês - AAMI) da *American National Standards Institute* (ANSI) desenvolveu uma norma (ANSI/AAMI EC57:1998/(R)2008) divulgada em 1998 e atualizada em 2008 (ANSI/AAMI, 2008) regulamentando quais arritmias devem ser detectadas pelos equipamentos/algoritmos destinados a este fim. A norma recomenda a classificação dos batimentos em 15 classes agrupadas em 5 grupos (super-classes): batimentos normais (N); *supraventricular ectopic* (SVEB); *Ventricular ectopic* (V); *Fusion* (F); e *Unknown* (Q).

Investigando-se a literatura, observa-se que nenhum método tentou tirar vantagens de informações relacionadas com a taxonomia dos batimentos cardíacos, ou seja, da hierarquia natural que os batimentos possuem. Encontra-se somente um trabalho (Park et al., 2008) no qual os autores dizem fazer uso de classificação hierárquica para classificação de arritmias no sinal de ECG. Todavia, de acordo com (Silla Jr. e Freitas, 2011), muito autores confundem problemas de classificação multiclasse com classificação hierárquica ou cometem o erro conceitual de dividir o problema de forma hierárquica, criando-se meta classes pelo agrupamento de classes similares, que é a abordagem proposta em (Park et al., 2008).

Como mencionado anteriormente, a própria AAMI organiza as classes de batimentos em uma hierarquia de árvore, no qual as 15 classes de batimentos podem ser vistas como folhas. As classes nos níveis intermediários (*i.e.*, N, SVEB, VEB, F e Q) podem fornecer informações adicionais, que por sua vez podem ser aproveitadas pela técnica de classificação chamada Classificação Hierárquica (Silla Jr. e Freitas, 2011).

Este trabalho tem dois objetivos principais. Primeiro, elaborar uma revisão da literatura dos métodos destinados à classificação de arritmias em sinais de ECG. E, segundo, propor um novo método para classificação de arritmias baseado em classificação hierárquica. Como objetivo secundário, propõe-se investigar novas características para representação do batimento cardíaco baseadas em uma representação 2D do sinal de ECG, o Vectorcardiograma (VCG), e redes complexas. Além de investigar o uso de uma abordagem *wrapper* para seleção de características com análise de sensibilidade do classificador para acelerar o processo, neste contexto de classificação.

Alguns resultados discutidos nesta dissertação de mestrado foram publicados em anais de conferências. Um deles nos anais do “*12th Annual International Conference on Bioinformatics & Computational Biology (BIOCOMP’11)*” (Luz e Menotti, 2011b) e o outro no “*33rd Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC’11)*” (Luz e Menotti, 2011a). Estes artigos fazem uma crítica aos métodos que visam classificação de arritmias em sinal de ECG com relação ao esquema utilizado para construção (aprendizado) dos modelos para classificação e a avaliação dos métodos. Esta crítica é apresentada em detalhes na Seção 2.3.

Sumarizando, as contribuições deste trabalho são:

- Uma revisão de literatura atualizada sobre o tema (a descrição do estado da arte).
- Uso de classificação hierárquica na classificação de arritmias em sinais de ECG e de abordagem *wrapper* para seleção de características.
- Extração e avaliação de novas características a partir do VCG e do intervalo RR e segmento QRS (relativizados) para classificação de arritmias.

O restante deste texto é organizado da seguinte forma: o Capítulo 2 apresenta uma fundamentação teórica básica, para posterior entendimento do método proposto e experimentos; o Capítulo 3 trata da revisão da literatura e os trabalhos correlatos a esta dissertação; o Capítulo 4 descreve o método proposto; a descrição dos resultados experimentais é apresentada no Capítulo 5; e por fim, o Capítulo 6 apresenta as conclusões finais e trabalhos futuros.

## Capítulo 2

# Fundamentação Teórica Básica Sobre Classificação de Arritmias

Este capítulo descreve e discute aspectos relacionados à metodologia para avaliação de algoritmos destinados à classificação de arritmias. Esses aspectos são apresentados aqui para familiarizar o leitor do trabalho com os principais conceitos relacionados de forma que o entendimento de vários termos possa ocorrer nos próximos capítulos. Também aproveitamos este capítulo para introduzir um conceito importante neste trabalho, *i.e.*, a classificação hierárquica.

A Seção 2.1 apresenta um protocolo de testes desenvolvido pela AAMI. A Seção 2.2 descreve características do banco de dados mais utilizado na literatura para avaliação de métodos de classificação de arritmias que também é utilizado neste trabalho. A Seção 2.3 apresenta algumas críticas relacionadas ao esquema de seleção de conjunto de dados para aprendizado dos métodos para classificação de arritmias e seu impacto nos resultados são discutidos. E por fim, a Seção 2.4 explicita o conceito de classificação hierárquica e o diferencia de classificação plana.

### 2.1 A norma da *Association for the Advancement of Medical Instrumentation* (AAMI)

As várias base de dados contendo batimentos cardíacos arrítmicos agrupados em registros de pacientes, disponíveis livremente, permitiram a criação de um protocolo para padronização da avaliação dos métodos para classificação automática de arritmia. Este protocolo foi desenvolvido pela AAMI e está especificado pela norma ANSI/AAMI EC57:1998/(R)2008 (ANSI/AAMI, 2008). A norma define uma forma para realizar os testes e reportar os resultados obtidos com o objetivo de torná-los reproduzíveis e comparáveis.

O uso de cinco bases de dados é recomendado pela norma:

- *AHA: The American Heart Association Database for Evaluation of Ventricular Arrhythmia Detectors* (80 registros de 35 minutos cada)
- *CU: The Creighton University Sustained Ventricular Arrhythmia Database* (35 registros de 8 minutos cada).
- *ESC: The European Society of Cardiology ST-T Database* (90 registros de 2 horas cada)
- *MIT-BIH: The Massachusetts Institute of Technology - Beth Israel Hospital Arrhythmia Database* (48 registros de 30 minutos cada)
- *NST: The Noise Stress Test Database* (12 registros de ECG de 30 minutos cada, mais 3 registros com excesso de ruídos)

A base de dados mais representativa é a base de dados de arritmia do MIT-BIH, isto é, o que contém a maior diversidade de tipos de arritmias/batimentos e, por isso, ele é utilizado na maior parte dos trabalhos publicados. Ela também foi a primeira base de dados disponível para tal objetivo e foi constantemente aprimorada durante os anos (Moody e Mark, 2001). Esta base foi a única utilizado nesta dissertação e é descrita em detalhes na Seção 2.2.

Pelas datas de publicação das bases e da norma da AAMI, acredita-se que essas bases foram criadas antes do desenvolvimento da AAMI. Somente depois do surgimento da norma é que as anotações/avaliações manuais sobre cada batimento foram realizadas. Essas anotações por batimento de classe e de pontos fiduciais (*e.g.*, ponto R, máxima amplitude do batimento) são fundamentais tanto para o desenvolvimento quanto para avaliação de método automáticos de classificação de arritmias. A norma também especifica como devem ser feitas as anotações dos bancos de dados e um exemplo pode ser visto na Figura 2.1, em que se tem a derivação II na parte superior da figura, a derivação V1 na inferior e algumas anotações no centro. Observe que nesta ilustração temos batimentos de vários tipos (N, V, A, T) que serão descritos em breve.




Figura 2.1: Exemplo de anotação do banco de dados do MIT-BIH.

Vale ressaltar que também é recomendado que os registros de pacientes com marca-passo sejam removidos (todos os batimentos). Segmentos de dados contendo *ventricular flutter* ou *fibrillation* (VF) também devem ser excluídos da análise.

Apesar da existência de vários tipos de arritmias cardíacas, a AAMI recomenda que somente alguns tipos devem ser detectados pelos equipamentos/métodos. São 15 as classes de batimentos recomendadas e essas classes devem ser agrupadas em cinco superclasses: *Normal* (N), *Supraventricular ectopic beat* (SVEB), *Ventricular ectopic beat* (VEB), *Fusion beat* (F) e *Unknown beat* (Q). A Tabela 2.1 ilustra as 15 classes e seus símbolos, bem como a hierarquia dos 5 grupos (superclasses).

Tabela 2.1: Principais tipos de batimentos presentes no banco de dados do MIT-BIH.

Grupo	Símbolo	Classe
<b>N</b> Qualquer batimento não categorizado como S, V, F ou Q	N ou . L R e j	<i>Normal beat</i> <i>Left bundle branch block beat</i> <i>Right bundle branch block beat</i> <i>Atrial escape beat</i> <i>Nodal (junctional) escape beat</i>
<b>SVEB</b> <i>Supraventricular ectopic beat</i>	A a J S	<i>Atrial premature beat</i> <i>Aberrated atrial premature beat</i> <i>Nodal (junctional) premature beat</i> <i>Supraventricular premature beat</i>
<b>VEB</b> <i>Ventricular ectopic beat</i>	V E	<i>Premature ventricular contraction</i> <i>Ventricular escape beat</i>
<b>F</b> <i>Fusion beat</i>	F	<i>Fusion of ventricular and normal beat</i>
<b>Q</b> <i>Unknown beat</i>	P ou / f U	<i>Paced beat</i> <i>Fusion of paced and normal beat</i> <i>Unclassifiable beat</i>

As medidas recomendadas pela AAMI para avaliação dos métodos são *Sensitivity* (Se), *Positive Predictivity* (+P), *False Positive Rate* (FPR) e Acurácia Global (Acc). *Sensitivity* e *Positive Predictivity* também são conhecidas na literatura por *Recall* e *Precision*, respectivamente. A acurácia global pode ser fortemente enviesada pelo resultado da classe majoritária. Desta forma, as três primeiras medidas são as mais relevantes para comparação dos métodos, já que a base apresenta forte desbalanceamento entre as classes.

O cálculo das medidas é baseado em matrizes de confusão que são detalhadamente apresentadas na Tabela 2.2. Em destaque na Tabela 2.2(a) e Tabela 2.2(b), em tons mais escuros, destacam-se os valores para cálculo dos falso negativos e positivos para as classes VEB e SVEB, respectivamente. Observe que de acordo com essa tabela, que segue a norma AAMI, não é preciso penalizar a *positive predictivity* da classe VEB ( $VEB + P$ ) com os falsos positivos VEB de F e Q, *i.e.*,  $Fv$  e  $Qv$  (em branco na Tabela 2.2(a)). Já para a *positive predictivity* da classe SVEB ( $SVEB + P$ ), o falso positivo  $Qv$  também não precisa entrar no cálculo (em branco na Tabela 2.2).

Tabela 2.2: Cálculo de avaliação dos métodos a partir de matrizes de confusão. Fonte (de Chazal et al., 2004).

(a) VEB						(b) SVEB						(c) Geral									
Referência	Algoritmo					Referência	Algoritmo					Referência	Algoritmo								
	n	s	v	f	q		n	s	v	f	q		n	s	v	f	q	soma			
	N	Nn	Ns	Nv	Nf		Nq	N	Nn	Ns	Nv		Nf	Nq	N	Nn	Ns	Nv	Nf	Nq	ΣN
	S	Sn	Ss	Sv	Sf		Sq	S	Sn	Ss	Sv		Sf	Sq	S	Sn	Ss	Sv	Sf	Sq	ΣS
	V	Vn	Vs	Vv	Vf		Vq	V	Vn	Vs	Vv		Vf	Vq	V	Vn	Vs	Vv	Vf	Vq	ΣV
	F	Fn	Fs	Fv	Ff		Fq	F	Fn	Fs	Fv		Ff	Fq	F	Fn	Fs	Fv	Ff	Fq	ΣF
	Q	Qn	Qs	Qv	Qf		Qq	Q	Qn	Qs	Qv		Qf	Qq	Q	Qn	Qs	Qv	Qf	Qq	ΣQ
																			Σ		
$TN_V = Nn + Ns + Nf + Nq$ $+ Sn + Ss + Sf + Sq$ $+ Fn + Fs + Ff + Fq$ $+ Qn + Qs + Qf + Qq$						$TN_S = Nn + Nv + Nf + Nq$ $+ Vn + Vv + Vf + Vq$ $+ Fn + Fv + Ff + Fq$ $+ Qn + Qv + Qf + Qq$						$TN = Nn$ $TP_V = Vv$ $TP_S = Ss$ $TP_F = Ff$ $TP_Q = Qq$ $Sp = TN/\Sigma N$									
$FN_V = Vn + Vs + Vf + Vq$ $TP_V = Vv$ $FP_V = Nv + Sv$						$FN_S = Sn + Sv + Sf + Sq$ $TP_S = Ss$ $FP_S = Ns + Vs + Fs$						$VEB Se : \text{veja Tabela 2.2(a)}$ $SVEB Se : \text{veja Tabela 2.2(b)}$ $F Se = TP_F/\Sigma F$ $Q Se = TP_Q/\Sigma Q$									
$VEB Se = TP_V/(TP_V + FN_V)$ $VEB + P = TP_V/(TP_V + FP_V)$ $VEB FPR = FP_V/(TN_V + FP_V)$						$SVEB Se = TP_S/(TP_S + FN_S)$ $SVEB + P = TP_S/(TP_S + FP_S)$ $SVEB FPR = FP_S/(TN_S + FP_S)$															
$VEB Acc = \frac{TP_V + TN_V}{TP_V + TN_V + FP_V + FN_V}$						$SVEB Acc = \frac{TP_S + TN_S}{TP_S + TN_S + FP_S + FN_S}$						$Acc = \frac{TN + TP_S + TP_V + TP_F + TP_Q}{\Sigma}$									

Abreviações: *Acc*: Acurácia, *F*: Grupo(superclasse) de batimentos Fusão, *FPR*: *False Positive Rate*, *N*: Grupo(superclasse) de batimentos normais, *+P*: *Positive predictivity*, *Q*: Grupo(superclasse) de batimento desconhecidos, *Se*: *Sensitivity*, *Sp*: *Specificity*, *S* & *SVEB*: Grupo(superclasse) de batimentos *Supraventricular ectopic*, *V* & *VEB*: Grupo(superclasse) de batimentos *Ventricular ectopic*.

Tabela 2.3: Exemplo de exibição de resultados, segundo a norma AAMI.

Registro	Acc	N			SVEB			VEB			F			Q		
		Se/+P/FPR			Se/+P/FPR			Se/+P/FPR			Se/+P/FPR			Se/+P/FPR		
101	99.5	99.7	99.8	60.0	33.3	12.5	0.4	—	—	0.0	—	—	0.0	0.0	—	0.0
106	72.5	97.5	100.0	0.0	—	0.0	27.5	0.0	—	0.0	—	—	0.0	—	—	0.0
108	97.2	98.3	99.7	21.7	75.0	6.4	2.5	0.0	—	0.0	0.0	—	0.0	—	—	0.0
109	95.9	97.4	99.5	27.5	—	0.0	3.7	0.0	—	0.0	0.0	—	0.0	—	—	0.0
...	...	...			...			...			...			...		
215	3.0	3.1	99.0	0.6	100.0	0.1	97.1	0.0	—	10.0	90.0	—	60.0	—	—	0.0
220	98.5	99.4	99.0	21.3	78.7	87.1	0.6	—	—	0.0	—	—	0.0	—	—	0.0
223	79.8	98.6	94.7	20.0	86.3	13.2	16.3	0.0	—	30.0	0.0	—	0.0	—	—	0.0
Média	75.5	83.0	98.1	14.4	45.8	4.3	19.2	0.0	0.0	4.5	50.0	0.0	10.0	0.0	0.0	0.0

A norma também sugere que os resultados sejam apresentados de forma global, considerando-se cada batimento com o mesmo peso (*gross statistics* - média. Também sugere que os resultados sejam exibidos por registro, como exemplifica a Tabela 2.3. Observe que um registro de paciente é composto por milhares de batimentos, normalmente adquiridos em um intervalo de tempo fixo e finito.

## 2.2 MIT-BIH

O banco de dados do MIT-BIH é utilizado pela grande maioria dos trabalhos publicados na literatura. Ele contempla os cinco grupos de arritmias propostos pela AAMI como ilustra a Tabela 2.1.

O banco contém 48 registros de batimentos cardíacos, de aproximadamente 30 minutos de duração, amostrados a 360Hz, pertencentes a 47 pacientes diferentes - existem dois registros para um mesmo paciente. Os registros foram escolhidos em um conjunto de mais de 4000 gravações a partir de *Holters* do *Beth Israel Hospital Arrhythmia Laboratory* entre os anos de 1975 e 1979. Dos 48 registros, 23 (com números/IDs variando entre 100 a 124, com duas ausências) foram escolhidos aleatoriamente neste conjunto. Outros vinte e cinco registros (com números/IDs variando entre 200 a 234) desse conjunto foram selecionados de forma a se obter uma representação dos 15 tipos de batimentos que formam os 5 grupos propostos pela AAMI. Também alguns deles apresentam situações raras e de difícil classificação, a fim de se criar uma base que contemple situações diversas. Os sinais foram extraídos de 25 homens com idade variando entre 32 e 89 anos e de 22 mulheres com idade entre 23 e 89 anos. Cada registro contém duas derivações de ECG e na maioria deles a derivação principal (ou derivação A) é a derivação II modificada (eletrodos no peito). A outra derivação (derivação B) é usualmente a derivação V1 modificada, mas sabe-se que em alguns registros essa derivação pode ser a V2, V5 ou V4 (Goldberger et al., 2000). De forma geral, utiliza-se a derivação A para se detectar os batimentos, já que complexo o QRS é mais proeminente nessa derivação. A derivação B favorece a classificação das arritmias do tipo SVEB e VEB (Goldberger et al., 2000).

Cada batimento do banco de dados do MIT-BIH foi cuidadosamente analisado por no mínimo dois especialistas em cardiologia. Após o consenso da classe em que o batimento pertence, anotações conforme recomendações da AAMI foram realizadas. Essas anotações (ou rótulos) são utilizadas para o aprendizado supervisionado de métodos para classificação automática de arritmias e também para avaliação desses. A base de dados e informações de utilização e anotações podem ser obtidos em (Goldberger et al., 2000).

Os tipos de batimentos encontrados no banco de dados de arritmia do MIT-BIH cobrem todas as classes da AAMI (Tabela 2.1) e uma totalização da distribuição de batimentos por classes dos 48 registros do banco de dados MIT-BIH é apresentada na Tabela 2.4. A distribuição de batimentos por classes de cada um dos 44 registros usados nos experimentos (os outros 4 registros são de pacientes com marca-passo) é apresentada no Capítulo 5.

Tabela 2.4: Divisão de tipos de batimento no banco de dados do MIT-BIH.

Grupo AAMI	Tipos de batimentos	% do total	Qde. de batimentos
Normal	N, e, j, L, R	82,78	90631
SVEB	A, a, J, S	2,54	2781
VEB	V, E	6,60	7236
F	F, e, j, L, R	0,73	803
P(marca-passo)	/, f	7,32	8010
Q	U	0,03	33
Total		100	109494



### 2.3 O problema da escolha dos batimentos para avaliação dos métodos

A norma da AAMI especifica um protocolo para testes e avaliação dos métodos de classificação. Entretanto, ela não especifica quais pacientes/batimentos devem ser utilizados para a construção do modelo para classificação (treino) e quais devem ser utilizados para o teste. Contudo, em (de Chazal et al., 2004) mostrou-se que ao se utilizar batimentos de um mesmo paciente para a construção do modelo (etapa de treinamento do classificador) e também para o teste (avaliação do classificador), a avaliação do método tornava-se enviesada, pois os modelos tendiam a “aprender” particularidades dos batimentos do paciente de forma que na etapa de teste obtinham-se resultados significativamente melhores (Luz e Menotti, 2011a). Todavia, em um ambiente clínico, os métodos/algoritmos vão se deparar com batimentos de pacientes nunca vistos anteriormente.

Nesse sentido, no trabalho de de Chazal et al. (2004), foi proposta uma divisão dos batimentos em dois conjuntos a fim de tornar os testes mais coerentes com a realidade. O primeiro conjunto composto por todos os batimentos dos registros 101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205, 207, 208, 209, 215, 220, 223 e 230 é chamado de **dataset 1** (DS1), e outro composto pelos registros 100, 103, 105, 11, 113, 117, 121, 123, 200, 202, 210, 212, 213, 214, 219, 221, 222, 228, 231, 232, 233 e 234 é chamado **dataset 2** (DS2). De acordo com os autores, estes registros foram primeiramente divididos em duas partições: registros pares e ímpares. A seleção de registros final foi alcançada trocando-se alguns registros entre as partições a fim de se balancear as classes. A distribuição de batimentos desses conjuntos pode ser vista na Tabela 2.5. Observe que os dois conjuntos têm aproximadamente a mesma quantidade de batimentos por classe, exceto para a classe SVEB que tem a proporção de 1 (DS1) para 2 (DS2), e somados ultrapassam 100 mil batimentos. Vale ressaltar que os registros 201 e 202 são do mesmo paciente e estão em conjuntos diferentes.

Tabela 2.5: Distribuição de batimentos por classes dos conjuntos/partições propostos por de Chazal et al. (2004)

Partição	N	SVEB	VEB	F	Q	Total
DS1	45866	944	3788	415	8	51021
DS2	44259	1837	3221	388	7	49712
DS1+DS2	90125	2781	7009	803	15	100733

Na literatura, a grande maioria dos trabalhos encontrados não se preocupa com esta questão sobre o esquema de seleção de batimentos dos pacientes para construção e avaliação do modelo. A Tabela 2.6 lista os principais trabalhos publicados na literatura agrupados segundo o esquema de seleção de batimentos: seleção aleatória (batimentos do mesmo pacientes

podem aparecer tanto no treino quanto no teste); seleção segundo esquema proposto por de Chazal et al. (2004); e outros que se preocuparam com a forma de construção e a avaliação do classificador usando batimentos de pacientes diferentes. Aproximadamente 10% dos trabalhos citados aqui seguem as recomendações propostas pela AAMI e tomam o cuidado de não misturar batimentos dos mesmos pacientes para a construção dos modelos e para o teste. Isto inviabiliza comparações entre os métodos, já que a grande maioria dos autores não seguiram um mesmo protocolo de avaliação. Portanto, esses (agrupados na Tabela 2.6 como de seleção aleatória) resultados reportados não podem ser levados em conta do ponto de vista clínico, pois os valores reportados naqueles experimentos são provavelmente superestimados (diferentes da realidade), em termos de acurácia.

Tabela 2.6: Lista de trabalhos agrupados de acordo com esquemas utilizados para treinamento e teste dos métodos. # Métodos que seguem a norma sugerida pela AAMI. \* Métodos que necessitam de treinamento com batimentos do paciente a ser analisado, chamados adaptativos (classificação semi-automática).

Esquema	Trabalhos
Seleção Aleatória	(Coast et al., 1990)#, (Clarkson et al., 1995), (Minami et al., 1999), (Lagerholm et al., 2000), (Osowski e Linh, 2001), (Owis et al., 2002), (Tsipouras et al., 2002), (Acharya et al., 2003), (Jung e Tompkins, 2003), (Christov e Bortolan, 2004), (Mehmet, 2004), (Osowski et al., 2004), (Osowski e Hoai, 2004), (Gao et al., 2005), (Güler e Übeyli, 2005), (Lee et al., 2005), (Lin et al., 2005), (Rodriguez et al., 2005), (Song et al., 2005), (Exarchos et al., 2005), (Andreao et al., 2006), (Karimifard et al., 2006), (Özbaya et al., 2006), (Bortolan et al., 2007), (Ceylanand e Özbay, 2007), (Exarchos et al., 2007), (Polat e Günes, 2007), (Tsipouras et al., 2007), (Übeyli, 2007), (Yu e Chen, 2007), (Korürek e Nizam, 2008), (Lin et al., 2008a), (Minhas e Arif, 2008), (Asl et al., 2008), (Osowski et al., 2008), (Polat et al., 2008), (Yu e Chou, 2008), (Ceylan et al., 2009), (Chua et al., 2009), (Kim et al., 2009), (Mahesh et al., 2009), (Moavenian e Khorrami, 2010), (Tavakoli et al., 2009), (Übeyli, 2009), (Wen et al., 2009), (Yu e Chou, 2009), (Gomes et al., 2010), (Khorrami e Moavenian, 2010), (Korürek e Doğan, 2010), (Kim et al., 2010), (Mishra e Raghav, 2010), (Neto et al., 2010), (Özbay e Tezel, 2010), (Özcan e Gorgen, 2010), (Pasolli e Melgani, 2010), (Ye et al., 2010), (Parlitz et al., 2011), (Özbay et al., 2011), (Lanata et al., 2011), (Sufi e Khalil, 2011), (Yeh et al., 2012)
Seleção segundo (de Chazal et al., 2004)	(de Chazal et al., 2004)#, (de Chazal e Reilly, 2006)#*, (Soria e Martinez, 2009)#, (Ince et al., 2009)#, (Llamedo e Martínez, 2011)#, (Mar et al., 2011)#, (Park et al., 2008)#, (de Lannoy et al., 2010)#
Treino e teste com batimentos de pacientes diferentes	(Ham e Han, 1996), (Hu et al., 1997)*, (Dokur e Ölmez, 2001), (Jiang e Kong, 2007)#

Com objetivo de se reportar testes de acordo com o protocolo recomendado pela AAMI e de utilizar o esquema de divisão proposta em (de Chazal et al., 2004), alguns trabalhos, que apresentavam acurácia global próxima de 100% e não se preocupavam com o esquema

de seleção de batimentos, foram totalmente reimplementados. Observe que os métodos escolhidos para esse experimento são razoavelmente recentes (publicados nos últimos 10 anos) e contemplam o uso de diversos classificadores e várias formas de extração de características. Analisando-se os valores das Tabelas 2.8 e 2.7, pode-se observar que os resultados obtidos por um mesmo método de classificação usando-se um esquema de seleção aleatório, ou seja, em que os batimentos foram escolhidos aleatoriamente para compor os conjuntos de treino e teste, são significativamente superiores aos valores conseguidos com os testes utilizando-se a divisão proposta em (de Chazal et al., 2004). Observe que os valores obtidos nas Tabelas 2.8 e 2.7 utilizaram a mesma base de dados e foram executados na mesma arquitetura computacional.

Tabela 2.7: Resultados obtidos pelos métodos considerando-se conjunto de dados aleatórios para treino e teste com a base de dados de arritmia do MIT-BIH.

Método	Acurácia (%)	N		SVEB		VEB		F		Q	
		Se/+P (%)		Se/+P (%)		Se/+P (%)		Se/+P (%)		Se/+P (%)	
(Ye et al., 2010)	96,5	98,7	96,3	72,4	94,5	82,6	97,8	65,6	88,6	95,8	99,3
(Yu e Chou, 2008)	95,4	96,9	97,3	73,8	88,4	92,3	94,3	51,0	73,4	94,1	80,8
(Yu e Chen, 2007)	81,1	85,2	81,2	0,0	0,0	70,0	79,2	0,0	0,0	0,0	0,0
(Güler e Übeyli, 2005)	89,1	93,2	90,3	0,0	0,0	81,6	74,6	0,0	0,0	0,0	0,0
(Song et al., 2005)	98,7	99,5	98,9	86,4	94,3	95,8	97,4	73,6	90,2	0,0	0,0

Tabela 2.8: Resultados obtidos pelos métodos segundo esquema de divisão de registros proposto por de Chazal et al. (2004) com a base de dados de arritmia do MIT-BIH.

Método	Acurácia (%)	N		SVEB		VEB		F		Q	
		Se/+P (%)		Se/+P (%)		Se/+P (%)		Se/+P (%)		Se/+P (%)	
(Ye et al., 2010)	75,2	80,2	78,2	3,2	10,3	50,2	48,5	0,0	0,0	0,0	0,0
(Yu e Chou, 2008)	75,2	78,3	79,2	1,8	5,9	83,9	66,4	0,3	0,1	0,0	0,0
(Yu e Chen, 2007)	73,9	81,5	74,2	0,0	0,0	21,0	59,4	0,0	0,0	0,0	0,0
(Güler e Übeyli, 2005)	66,7	69,2	72,1	0,0	0,0	78,8	43,8	1,8	0,5	0,0	0,0
(Song et al., 2005)	76,3	78,0	83,9	27,0	48,3	80,8	38,7	0,0	0,0	0,0	0,0

Os resultados apresentados nesta seção sugerem que para se avaliar os métodos deve-se levar em conta um esquema de seleção no qual batimentos de um mesmo paciente não estejam presentes no conjunto de treino e teste. Os classificadores tendem a se especializar nos dados/batimentos dos pacientes da base de treinamento e, portanto, avaliar o método com batimentos de um mesmo paciente nas partições de treino e teste, mesmo que os batimentos sejam diferentes, torna a avaliação enviesada.

Também destaca-se que poucos autores têm se preocupado em seguir um padrão, como o proposto pela AAMI, para reportar resultados e avaliar os métodos, o que dificulta a comparação entre os trabalhos publicados na literatura. Vale ressaltar que o conteúdo desta última seção foi publicado em (Luz e Menotti, 2011a).

No método proposto nesta dissertação, que será apresentado no Capítulo 4, procura-se usar o esquema de divisão de batimentos proposto em (de Chazal et al., 2004) e seguir o

protocolo recomendado pela AAMI.

## 2.4 Classificação plana *versus* Classificação hierárquica

Um problema de classificação em que se deseja predir classes a partir de instâncias pode ser visto como uma árvore, ou um grafo direto acíclico (DAG), em que se tem um nó raiz e os valores possíveis para o atributo classe seriam as folhas (ver Figura 2.2). Um classificador chamado plano que não leva em consideração a taxonomia da árvore usualmente prediz apenas os nós folha dessa taxonomia. Contudo, vários problemas reais são de natureza hierárquica e a classificação pode ser favorecida com informações provindas da dela.




Figura 2.2: Exemplo de uma configuração hierárquica com dez classes.

### 2.4.1 Classificação hierárquica

Nesta seção, brevemente discutimos as abordagens de classificação hierárquica e definimos aquela que será utilizada como abordagem de classificação neste trabalho.

Para que um problema possa ser encarado de forma hierárquica é preciso ter uma taxonomia de classe, ou seja, uma árvore regular estruturada definida sob uma ordem  $(C, <)$  em que  $C$  é um conjunto finito de classes e a relação  $<$  é uma relação do tipo “IS-A”, que é uma relação anti-reflexiva, anti-simétrica e transitiva. O problema só é considerado classificação hierárquica se as 4 propriedades hierárquicas “IS-A” forem satisfeitas (Silla Jr. e Freitas, 2011). As propriedades são:

- Apenas um elemento é a raiz da árvore:  $R$
- Para todo  $C_i, C_j$ , pertencente a  $C$ ; se  $C_i < C_j$  então  $C_j$  não  $< C_i$

- Para todo  $C_i$ , pertencente a  $C$ ;  $C_i$  não  $< C_i$
- Para todo  $C_i, C_j, C_k$ , pertencente a  $C$ ; Se  $C_i < C_j < C_k$ ; então  $C_i < C_k$

Pela Figura 2.3 pode-se ver que o problema de classificação de arritmias satisfaz as 4 propriedades já citadas. Tem-se apenas um nó raiz (batimento). A propriedade anti-reflexiva é satisfeita pois, por exemplo, todo batimento do tipo SVEB é arritmico, mas nem todo batimento arritmico é SVEB. A árvore também é anti-simétrica pois um filho de nó não pode ser pai dele. E por fim, pode-se constatar que se um batimento, por exemplo, é do tipo A (“filho” de SVEB - ver Tabela 2.1) implica que ele é arritmico, o que está de acordo com a propriedade transitiva.

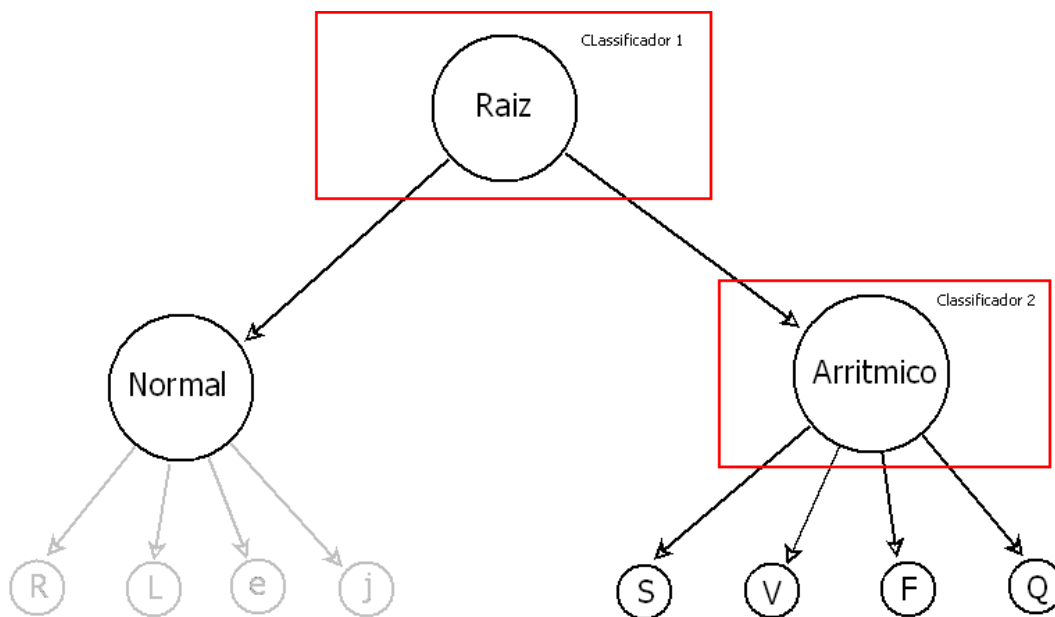


Figura 2.3: Esquema de níveis de classificação hierárquicos: Nível 1 - Normal/Arritmia, Nível 2 - S, V, F e Q.

Segundo Silla Jr. e Freitas (2011), existem duas abordagens de modelos hierárquicos: Abordagem global (*Big-Bang*) e Abordagem Local (*Top-Down*). Na abordagem global, apenas um classificador (relativamente complexo) é utilizado para classificar todas as classes (nós) de todos os níveis da árvore. A abordagem local consiste na criação de diversos classificadores, associados aos nós ou aos níveis da árvore.

Os métodos com abordagens locais são os mais populares na literatura. Segundo Silla Jr. e Freitas (2011), existem 3 abordagens de classificadores locais: LCN (*local classifier per node*); LCPN (*local classifier per parent node*); e LCL (*local classifier per level*). Em essência, considerando-se classificadores com abordagens locais, para cada exemplo novo no conjunto de teste, o sistema primeiramente classifica o primeiro nível (mais genérico), assim, ele usa essa informação para aprofundar na classificação do próximo nível (nós filhos). Abordagens do tipo

LCN e LCPN se adequam naturalmente para o problema da classificação de arritmias, contudo, a abordagem LCPN pode ser mais facilmente modelada, pela sua simplicidade. Diversos autores defendem que modelos hierárquicos com abordagens LCPN superaram modelos com classificação plana (Costa et al., 2008; Holden e Freitas, 2008). Desta forma, a abordagem LCPN foi escolhida para o problema de classificação abordado neste trabalho.

Na abordagem LCPN, a cada nó pai é associado um classificador (ver Figura 2.3). Para a construção dos modelos de classificação, várias políticas/regras foram propostas na literatura (Silla Jr. e Freitas, 2011). Tomando-se como base uma classe qualquer  $C_j$ , as políticas podem ser descritas como:

- Política “exclusiva”: Na qual apenas exemplos explicitamente rotulados como  $C_j$  são considerados positivos e todo o resto é negativo (inclusive os descendentes de  $C_j$ )
- Política “menos exclusiva”: Mesmo que a política exclusiva, porém os descendentes de  $C_j$  são excluídos do conjunto negativo.
- Política “menos inclusiva”: Inclui os descendentes no conjunto positivo. Todas as outras classes são conjuntos negativos.
- Política “inclusiva”: Conjunto positivo inclui todos pertencentes à classe e seus descendentes. Conjunto negativo exclui todos pertencentes a classe e seus descendentes, mais ancestrais de  $C_j$ .
- Política “irmãos (*siblings*)”: Conjunto positivo consiste em  $C_j$  e seus descendentes enquanto o conjunto negativo consiste em nós no mesmo nível e irmãos, e seus descendentes.
- Política “irmãos exclusivos (*exclusive siblings*)”: Conjunto positivo consiste em  $C_j$  e negativo apenas seu(s) irmão(ões).

Para o problema da classificação de arritmias, a política “irmãos (*siblings*)” foi escolhida, pois de acordo com Silla Jr. e Freitas (2011), políticas mais inclusivas tendem a ter melhores resultados e a política “inclusiva” descrita acima não se encaixa para o caso em questão.

## Capítulo 3

# Revisão da Literatura

Este capítulo apresenta os trabalhos correlatos a esta dissertação e discute as principais técnicas utilizadas para a construção dos sistemas automáticos destinados à classificação de arritmias. A Seção 3.1 trata das técnicas de pré-processamento mais utilizadas em sinais de ECG, enquanto a Seção 3.2 apresenta o conceito de segmentação para sinais de ECG as técnicas comumente empregadas. Essas duas primeiras sub-seções tratam brevemente desses assuntos pois eles não são o foco dessa dissertação. A Seção 3.3 trata do ponto chave para o sucesso da classificação de arritmias; a extração de características. Por fim, a Seção 3.4 aborda os algoritmos de classificação mais populares na literatura.

### 3.1 Pré-processamento

Entre as tantas propostas para a redução de ruídos em sinais de ECG, a mais simples e amplamente utilizada é a implementação de filtros digitais recursivos de resposta ao impulso finito (FIR) (Lynn, 1979), que foi viabilizada computacionalmente com o avanço dos microcontroladores e microprocessadores. Este método funciona bem para atenuação de faixas de frequências conhecidas, como o ruído proveniente da rede (50Hz ou 60H), pois ele permite uma rápida e fácil implementação de um filtro rejeita-banda. O problema com esta abordagem é que nem sempre a frequência do ruído é conhecida. Para resolver esse problema, filtros para várias faixas de frequências teriam que ser aplicados ao sinal. Mas o uso indiscriminado de filtros, como por exemplo, filtros passa-altas e passa-baixas, acabam distorcendo a morfologia do sinal e, muitas vezes, deixando-o inutilizado para o uso em diagnóstico de doenças cardíacas. Arquiteturas com filtros adaptativos (Ferrara e Widraw, 1982; Yelderman et al., 1983) também foram empregadas para remoção de ruídos em sinais de ECG, mas de acordo com Thakor e Zhu (1991) essa técnica possui limitações e não oferece grandes vantagens sobre os filtros digitais FIR. Em (Xue et al., 1992), conseguiu-se contornar parte do problema utilizando filtros adaptativos baseados em redes neurais e aprimorou-se significativamente

a redução de ruídos. Essa estratégia proporcionou uma melhor detecção do complexo QRS, se comparado ao mesmo método que utiliza filtros adaptativos lineares.

Atualmente têm-se utilizado muitos métodos baseados em transformadas Wavelet para remoção de ruídos, visto que além de mais simples do ponto de vista computacional, preservam o sinal evitando perda de detalhes fisiológicos importantes (Singh e Tiwari, 2006).

Em (Sayadi e Shamsollahi, 2007), uma modificação da transformada Wavelet chamada de *multiadaptive bionic Wavelet transform* foi proposta e aplicada à redução de ruído e variação de linha base no sinal de ECG. O método apresentou resultados superiores aos métodos baseados em transformada Wavelet tradicional.

Outros métodos também apresentaram resultados interessantes, como em (Sameni et al., 2007), em que os autores propuseram o uso de filtros Bayesianos não-lineares para redução de ruídos no sinal de ECG. Um novo algoritmo baseado na estrutura *extended kalman filter* (EKF) (Sayadi e Shamsollahi, 2008), que incorpora os parâmetros do *ECG dynamical model* (EDM) para redução de ruído e compressão do sinal de ECG, trouxe uma contribuição significativa, visto que o método se mostrou melhor que os métodos mais eficazes até então.

Técnicas para pré-processamento do sinal de ECG são bastante exploradas, todavia, a escolha de qual método utilizar está intrinsecamente ligada ao objetivo final da pesquisa. Métodos cujo foco está voltado à segmentação do sinal de ECG (detecção do complexo QRS) tendem a precisar de um pré-processamento diferente de métodos voltados à classificação automática de arritmias. Embora existam alguns estudos relacionando técnicas de pré-processamento com o desempenho final da classificação automática de arritmias, como em (Güler e Übeyli, 2005), estes são em número insuficiente e mais pesquisas nessa área devem ser encorajadas.

## 3.2 Segmentação

A segmentação do ECG consiste em delimitar a parte de maior interesse, o complexo QRS, visto que ele reflete a atividade elétrica no coração durante a contração ventricular. Uma vez feita a segmentação dos complexos QRS, *i.e.*, determinar o momento exato em que o evento ocorreu e então fazer aquisição de uma parte do sinal, podem-se obter diversas informações fisiológicas, como por exemplo, a frequência cardíaca, largura do pulso, amplitude, *etc.* A partir disso, técnicas para extração de características, que servirão de base para uma classificação automática, podem ser aplicadas.

Algoritmos para detecção do complexo QRS são motivos de estudos a mais de três décadas (Pan e Tompkins, 1985; Hu et al., 1990; Afonso et al., 1999; Sayadi e Shamsollahi, 2009) e a evolução dos algoritmos e métodos refletem a evolução do poder de processamento dos computadores. Com a facilidade de obtenção de computadores mais rápidos, autores passaram a se importar menos com o custo computacional e mais com a precisão, que para este caso, segmentação do QRS, é usualmente descrita por duas medidas,



$$Sensitivity_{SEG} = \frac{TP}{TP + FN}, \quad (3.1)$$

e

$$Positive\ predictivity_{SEG} = \frac{TP}{TP + FP}, \quad (3.2)$$

em que  $TP$ ,  $FP$  e  $FN$  significam o número de batimentos corretamente segmentados, de segmentações que não correspondem a batimentos e de segmentações que deixaram de ser realizadas, respectivamente.

Para uma justa comparação entre os métodos destinados à detecção do complexo QRS, também é preciso que um banco de dados padrão seja utilizado. O mais utilizado, e recomendado pela ANSI/AAMI para validação de equipamentos médicos, é o banco de dados de arritmia do MIT-BIH (Massachusetts Institute of Technology, 2011). Embora outros bancos também sejam utilizados, como o banco de dados da AHA (American Heart Association, 1998), o banco de dados da CSE (van Bommel e Williams, 1990), entre outros. Todavia, de acordo com Kohler et al. (2002), muitos métodos apresentados na literatura não utilizam o banco de dados padrão ou utilizam apenas uma parte deles, o que torna difícil uma comparação justa entre os métodos.

Uma abordagem amplamente utilizada, por sua simplicidade e ainda assim com bons resultados publicados, é baseada em filtros digitais para atenuação de ruídos e remoção de flutuação de linha base, transformações não-lineares para realce da onda R e limiares de detecção adaptativos, proposta em (Pan e Tompkins, 1985). Métodos mais sofisticados já foram utilizados, como métodos baseados em redes neurais (Hu et al., 1990), algoritmos genéticos (Poli et al., 1995a), transformada Wavelet (Kadambe et al., 1999; Jung e Tompkins, 2003; Martinez et al., 2004), banco de filtros (Afonso et al., 1999), *Quad Level Vector* (Kim et al., 2010), entre outros. Mas, tanto métodos mais simples quanto mais sofisticados não apresentam grandes diferenças em termos de desempenho ( $Sensitivity_{SEG}$  e  $Positive\ predictivity_{SEG}$ ). Na Tabela 3.1, pode-se ver o desempenho de alguns métodos que utilizaram o banco de dados do MIT-BIH para avaliação dos resultados.

Alguns algoritmos também se propõem a identificar outras ondas associadas ao batimento cardíaco, como a onda P e onda T (Martinez et al., 2004; Laguna et al., 1994; Celler e Chazal, 1997; Sahambi et al., 1997), o que pode ser útil a métodos para classificação de arritmias, visto que mais informação do batimento poderá ser extraída.

Embora a detecção do complexo QRS não seja o foco deste trabalho, salienta-se a importância dessa etapa no processo de classificação de arritmias, visto que erros serão propagados e impactarão fortemente na classificação de arritmias. Entretanto, a grande maioria dos trabalhos analisados aqui utilizam bancos de dados em que os eventos relacionados ao batimento cardíaco, *i.e.*, os complexos QRS, são rotulados previamente, reduzindo a etapa de segmen-

Tabela 3.1: Algoritmos para segmentação do batimentos cardíaco.

Método	# batimentos	<i>TP</i>	<i>FP</i>	<i>FN</i>	% error	<i>Se</i> %	<i>P+</i> %
Martinez et al. (2004)	109428	109208	153	220	0.34	99.80	99.86
Moody e Mark (1982)	109428	107567	94	1861	1.79	98.30	99.91
Li et al. (1995)	104182	104070	65	112	0.17	99.89	99.94
Afonso et al. (1999)	90909	90535	406	374	0.86	99.59	99.56
Bahoura et al. (2007)	109809	109635	135	184	0.29	99.83	99.88
Lee et al. (1996)	109481	109146	137	335	0.43	99.69	99.88
Hamilton e Tompkins (1986)	109267	108927	248	340	0.54	99.69	99.77
Pan e Tompkins (1985)	109809	109532	507	227	0.71	99.75	99.54
Poli et al. (1995b)	109963	109522	545	441	0.90	99.60	99.50
Moraes et al. (2002)	N/R	N/R	N/R	N/R	N/R	99.22	99.73
Hamilton (2002)	N/R	N/R	N/R	N/R	N/R	99.80	99.80

tação a uma simples busca por um evento rotulado no banco de dados. Assim, os resultados reportados estão livres de erros providos desta etapa. Note que, por outro lado, em aplicações reais este erro deve ser considerado.

### 3.3 Extração de Características

A etapa de extração de características (ou atributos) é o ponto chave para o sucesso na classificação de arritmias em sinal de ECG. Qualquer informação extraída de um batimento cardíaco, utilizada para discriminar seu tipo, é considerada uma característica. As características podem ser extraídas de diversas formas, diretamente da morfologia da onda de ECG, tanto no domínio do tempo quanto no da frequência, ou do ritmo cardíaco.

A característica mais comum encontrada na literatura é calculada a partir do ritmo cardíaco (ou também *Heart Beat Interval*), também conhecida por intervalo RR. O intervalo RR é o tempo entre o pico R de um batimento com relação a outro batimento, que pode ser seu antecessor ou sucessor (ver Figura 3.1). Com exceção de pacientes que utilizam marca-passo, as variações percebidas na largura do intervalo RR estão correlacionadas com variações na morfologia da curva, frequentemente provocadas por arritmias (Clifford et al., 2006). Por isso, características do intervalo RR têm uma grande capacidade discriminatória de tipos de batimentos e alguns autores basearam seus métodos apenas em características do intervalo RR (Exarchos et al., 2005, 2007). Variações desta característica, a fim de se reduzir interferências de ruídos, também são muito comuns, como por exemplo a média do intervalo RR de um paciente em um intervalo de tempo (Ye et al., 2010).

Todavia, outras características extraídas de intervalos do batimento também são encontradas na literatura, como outras distâncias entre pontos fiduciais de um batimento cardíaco, como pode ser visto na Figura 3.1. Dentre estes intervalos, o intervalo QRS, ou a duração do complexo QRS, é o mais utilizado. Alguns tipos de arritmias provocam variações no intervalo QRS, fazendo com que esta característica seja um bom discriminante (de Chazal et al., 2004;




Figura 3.1: Pontos fiduciais e vários intervalos usuais de um batimento cardíaco. Fonte (Clifford et al., 2006).

Korürek e Doğan, 2010). Vale ressaltar que existem alguns algoritmos disponíveis para a determinação destes pontos fiduciais, como o proposto em (Laguna et al., 1994). A Tabela 3.2 mostra valores padrão para estes intervalos, para um adulto, saudável e sem anormalidades cardíacas.

Tabela 3.2: Atributos típicos de um sinal de ECG normal, com frequência cardíaca de 60 bpm (batidas por minutos) de um adulto saudável e derivação II. Fonte (Clifford et al., 2006).

Atributo	Valor normal	Variação normal
onda P	110 ms	$\pm 20$ ms
intervalo PQ/PR	160 ms	$\pm 40$ ms
largura do QRS	100 ms	$\pm 20$ ms
intervalo QT	400 ms	$\pm 40$ ms
amplitude de P	0.115 mV	$\pm 0.05$ mV
amplitude do QRS	1.5 mV	$\pm 0.5$ mV
nível ST	0 mV	$\pm 0.1$ mV
amplitude T	0.3 mV	$\pm 0.2$ mV

Características extraídas no domínio do tempo/frequência em conjunto com as caracterís-

ticas do intervalo RR têm produzido os melhores resultados publicados (de Chazal et al., 2004; Llamedo e Martínez, 2011). A forma mais simples de se extrair características no domínio do tempo é utilizando-se os pontos da própria curva de ECG segmentada, *i.e.*, o batimento cardíaco, como características (Wen et al., 2009; Özbay e Tezel, 2010) (ver Figura 3.2). Porém, utilizar amostras da curva como características é uma técnica não muito eficiente, pois além de se produzir um vetor de características de dimensão elevada (dependente de quantas amostras foram utilizadas para se representar o batimento), sofre-se com diversos problemas relacionados à escala e ao deslocamento do sinal com relação ao ponto central (pico R).




Figura 3.2: Sinal de ECG extraído do MIT-BIH AR DB, amostrado a 360Hz.

Com o propósito de reduzir a dimensionalidade das características, várias técnicas foram aplicadas diretamente nas amostras que compõem o batimento (em torno da pico R), como *principal component analysis* (PCA) (Castells et al., 2007; Ceylanand e Özbay, 2007; Kim et al., 2009), *independent component analysis* (ICA) (Barros et al., 1998; He et al., 2006; Yu e Chou, 2008, 2009), em que novos coeficientes são extraídos para se representar o batimento. Em (Chawla, 2009), um estudo comparativo entre o uso de PCA e ICA para redução de ruído e artefatos em sinais de ECG mostrou que PCA é uma técnica melhor para redução de ruídos e ICA é melhor para extração de características. O uso das duas técnicas combinadas pode oferecer grandes vantagens se comparado a resultados obtidos com abordagens clássicas.

Em (Özbaya et al., 2006), foram utilizadas técnicas de agrupamento diretamente nos pontos amostrados da curva, para redução de 106 amostras para 67 agrupamentos. Os autores também utilizaram a técnica de agrupamento para aumentar o número de características para 212, mas não houve diferenças significativas nos resultados.

Em (Asl et al., 2008), os autores utilizaram *Generalized Discriminant Analyses* (GDA) para redução de características do tipo *Heart Beat Interval*, para classificação de arritmias rítmicas. Autores reportaram acurácia próximas a 100% para esses tipos de arritmias utilizando-se o banco de dados de arritmias do MIT-BIH.

Técnicas mais simples como interpolação também têm sido utilizadas para redução do número de pontos para representação do batimento. Um exemplo é a técnica apresentada em (de Chazal et al., 2004), em que o batimento cardíaco originalmente representado por 250

amostras (aproximadamente 600ms de curva, com amostragem de 360hz) foi sub-amostrado para 18 amostras (ver Figura 3.3).

Outras técnicas também são utilizadas, como *linear predictive coding* (Ham e Han, 1996), *High order cummulants* (Osowski e Linh, 2001; Osowski et al., 2004), agrupamento (Özbaya et al., 2006; Ceylan et al., 2009; Osowski et al., 2008), *correlation dimension* e *largest lyapunov expoent* (Owis et al., 2002), transformada hermite (Jiang e Kong, 2007), *local fractal dimension* (LFD) (Mishra e Raghav, 2010).

Todavia, a maior parte dos trabalhos na literatura utiliza transformada Wavelet, e pesquisadores defendem que este é o melhor método para extração de características em sinais de ECG (Mehmet, 2004; Güler e Übeyli, 2005; Lin et al., 2008a).




Figura 3.3: Redução do número de características por meio de interpolação. Fonte (de Chazal et al., 2004).

A transformada Wavelet permite extração de informação tanto no domínio da frequência, quanto do tempo. Já a transformada de Fourier (Dokur e Ölmez, 2001), permite a análise apenas no domínio da frequência. Dentre os tipos de transformada Wavelet, a transformada Wavelet discreta (DWT), é a mais popular para classificação de ECG devido à sua fácil implementação.

Além da DWT, as transformadas Wavelet mais comuns, são *Continues Wavelet Transform* (CWT) e *Discrete Cosine Transform* (DCT). De acordo com Addison (2005), CWT permite uma poderosa análise em sinais não-estacionários, o que o torna uma excelente ferramenta para extração de características em ECG. Já o DWT provê uma metodologia para estudos das diferentes sub-bandas do sinal (níveis de decomposição) e pode ser uma poderosa ferramenta para compressão do sinal. Ainda em (Addison, 2005), o autor defende que o uso da DWT em

conjunto com CWT pode oferecer ganhos sob as metodologias atuais, em que autores utilizam apenas uma das transformadas.

De acordo com Güler e Übeyli (2005), a escolha da função Wavelet mãe utilizada para extração de características é crucial para o desempenho final do modelo de classificação. A escolha da transformada mãe deve ser cuidadosamente analisada, a fim de não se perder detalhes importantes do sinal de ECG.

Na literatura, várias características estatísticas dos coeficientes da transformada Wavelet são propostas, como média, desvio padrão, energia (Güler e Übeyli, 2005) e variância dos coeficientes (Yu e Chen, 2007). Estas características possuem grande vantagem, pois são imunes às variações da marcação dos pontos fiduciais.

A variância da função de autocorrelação é considerada uma medida de similaridade ou coerência entre um sinal e sua versão deslocada (Yu e Chen, 2007). Esta técnica é utilizada para extração de características, nos coeficientes Wavelet, em (Yu e Chen, 2007; Llamedo e Martínez, 2011) e tem se mostrado eficiente para discriminação de batimentos arritmicos.

### 3.3.1 Redução de Características

Alguns autores utilizaram técnicas para redução do espaço de características, após a aplicação da WT. Song et al. (2005) compararam PCA e LDA para redução de características para construção de modelos com *support vector machines* (SVM) (Cortes e Vapnik, 1995) e transformada wavelet. Os autores reportaram que resultados finais com características reduzidas por LDA foram melhores que PCA e até mesmo melhores que os resultados obtidos com a utilização de todas as características disponíveis. Em (Polat e Günes, 2007), foi utilizado PCA para se reduzir um espaço de características de dimensão 279 para 15, para classificação de 2 classes: anormal e normal. A acurácia do método com características reduzidas se manteve próxima da original, com 279 características.

Todavia, de acordo com (Llamedo e Martínez, 2011), muitos autores utilizam técnicas para a redução do espaço de características mas pouco se tem investigado sobre técnicas para seleção de características. Em (Llamedo e Martínez, 2011), pela primeira vez na literatura um algoritmo de seleção de características objetivando a classificação automática de arritmias foi empregado. Em (Llamedo e Martínez, 2011), uma busca flutuante para frente e para trás foi usada para seleção de características (Pudil et al., 1994), e com apenas 8 características selecionadas o método conseguiu valores superiores ao método estado-da-arte utilizado como referência. Recentemente, encontra-se um outro trabalho (Mar et al., 2011) que também fez uso de seleção de características usando classificadores como *Multi-layer perceptron* e Discriminantes lineares. Na opinião do autor dessa dissertação, esse último trabalho (Mar et al., 2011) não supera o anterior e também recente (Llamedo e Martínez, 2011).

### 3.3.2 Vectorcardiograma

O vectorcardiograma (VCG) é a representação em duas dimensões do ECG e reúne informação de ambas as derivações (ver Figura 3.4). Características extraídas do VCG foram utilizadas em alguns trabalhos (Bortolan et al., 2007; Soria e Martinez, 2009; Christov e Bortolan, 2004; Llamedo e Martínez, 2011). De acordo com (Goldberger et al., 2000), a classificação dos batimentos categorizados como SVEB e VEB pode ser favorecida por informações providas das derivações do tipo V1, V2 ou V4. Por isso, acredita-se que características extraídas do VCG podem ajudar a discriminar melhor as classes minoritárias, ou seja, SVEB e VEB. Nesta dissertação em especial, investiga-se o uso de tal representação em conjunto com redes complexas (Souza et al., 2011; Backes et al., 2009).




Figura 3.4: VCG construído a partir de batimentos do registro 202 do MIT-BIH. Figura adaptada de (Llamedo e Martínez, 2011).

### 3.3.3 Seleção de Características

Técnicas de seleção de características podem trazer diversos benefícios aos métodos de classificação, como aumento do poder de generalização dos algoritmos de classificação e redução do custo computacional, devido ao fato de se utilizar um número menor de características para a construção do modelo final. Contudo, em trabalhos analisados nesta dissertação, essas técnicas foram pouco exploradas. Técnicas estado-da-arte em seleção de atributos como Algoritmos

Genéticos (GA) (Oh et al., 2004; Yang e Honavar, 1998) e *particle swarm optimization* (PSO) (Wang et al., 2007; Lin et al., 2008b) podem trazer bons resultados e devem ser investigadas em trabalhos futuros.

### 3.4 Classificação

Com um conjunto de características escolhido, podem-se construir modelos para classificação de arritmias usando-se algoritmos de aprendizado de máquina (Duda et al., 2000; Bishop, 2006; Theodoridis e Koutroumbas, 2009). Os três algoritmos mais populares encontrados na literatura usados para esse fim são ***support vector machines*** (SVM) (Osowski et al., 2004, 2008; Song et al., 2005; Yu e Chou, 2009; Pasolli e Melgani, 2010; Khorrami e Moavenian, 2010; Parlitz et al., 2011; Asl et al., 2008; Ye et al., 2010; Özcan e Gurgun, 2010; Moavenian e Khorrami, 2010; Polat e Günes, 2007; Übeyli, 2007; Polat et al., 2008), **redes neurais artificiais** (ANN) (Hu et al., 1997; Minami et al., 1999; Yu e Chou, 2009; Ince et al., 2009; Mar et al., 2011; Übeyli, 2009; Özbay e Tezel, 2010; Ceylanand e Özbay, 2007; Lin et al., 2008a; Yu e Chou, 2008; Dokur e Ölmez, 2001; Osowski e Linh, 2001; Özbay et al., 2011; Ceylan et al., 2009; Lin et al., 2005; Lee et al., 2005; Neto et al., 2010; Gao et al., 2005; Güler e Übeyli, 2005; Mehmet, 2004; Yu e Chen, 2007; Christov e Bortolan, 2004; Jiang e Kong, 2007) e **discriminantes lineares** (de Chazal et al., 2004; Soria e Martinez, 2009; Llamedo e Martínez, 2011; Mar et al., 2011).

Entretanto, vários outros métodos podem ser encontrados usando outros algoritmos de aprendizado de máquina, como **árvore de decisão** (Mahesh et al., 2009; Rodriguez et al., 2005; Exarchos et al., 2007), **vizinho mais próximo** (Korürek e Nizam, 2008; Owis et al., 2002; Lanatá et al., 2011; Minhas e Arif, 2008; Tavakoli et al., 2009), **baseados em agrupamento** (Sufi et al., 2009; Wen et al., 2009; Yeh et al., 2012; Lagerholm et al., 2000), ***hidden markov models*** (Coast et al., 1990; Gomes et al., 2010), **classificadores *hyperbox*** (Bortolan et al., 2007) e **modelos definidos por conjuntos de regras** (Tsipouras et al., 2002; Exarchos et al., 2005; Tsipouras et al., 2007).

Métodos que utilizam árvore de decisão permitem uma interpretação das decisões tomadas pelo modelo (Exarchos et al., 2007). Todavia este tipo de método não é eficiente para características contínuas (pertencente ao conjunto dos números reais) e para vetores de características de altas dimensões. Assim, métodos que utilizaram árvore de decisão utilizaram poucas características, como em (Exarchos et al., 2007), em que apenas características do intervalo RR foram expostas na árvore. Já os classificadores *hyperbox*, além de prover interpretação de alto nível das regras de classificação, são mais eficientes para vetores de características de dimensões maiores (Bortolan et al., 2007).

Os métodos com o maior nível de interpretação são os métodos que utilizam conjunto de regras. O conjunto de regras apresentado em (Tsipouras et al., 2002; Exarchos et al.,



2005; Tsipouras et al., 2007) foi obtido junto a cardiologistas e são relacionados a *tachogram morphology* em eventos de arritmia. Métodos construídos com conjunto de regras usualmente têm pior desempenho, com relação a outros métodos propostos na literatura. Entretanto, nenhum teste utilizando um esquema mais justo de comparação, como o proposto em (de Chazal et al., 2004), nem as recomendações da AAMI, foi feito com métodos que utilizam conjunto de regras.

Nas próximas sub-seções, os três classificadores mais utilizados serão discutidos com mais detalhes.

### 3.4.1 SVM

De acordo com Cortes e Vapnik (1995); Scholkopf e Smola (2002), SVMs são métodos que constroem classificadores a partir da criação de hiper-planos em um espaço  $n$ -dimensional, *i.e.*, desenhando “linhas” em um espaço  $n$ -dimensional que são capazes de separar exemplos de diferentes classes. Estes hiper-planos são criados com o auxílio de pontos localizados nas bordas dos conjuntos, chamados vetores de suporte.

Quando confrontados com problemas não-lineares, SVMs criam um mapeamento entre um conjunto de valores de entrada (exemplos) e um espaço de características, no qual essas classes não-lineares de contorno iniciais são feitas linearmente separáveis por uma transformação (ou mapeamento) do espaço de características. Esse mapeamento é feito por um conjunto de funções matemáticas chamadas *kernels*. Depois de realizar esse mapeamento, SVMs utilizam um algoritmo iterativo de treinamento para minimizar uma função de erro.

O SVM é um dos classificadores mais populares encontrados na literatura para classificação de arritmias em sinais de ECG, entretanto, poucos trabalhos revisados levaram em consideração as recomendações da AAMI e/ou tiveram o cuidado de não misturar batimentos de um mesmo paciente nos conjuntos de treino e teste. Assim, a maioria dos trabalhos publicados na literatura apresentam resultados irreais, do ponto de vista clínico, e não podem ser utilizados como base de comparação. Já em (Park et al., 2008), os autores utilizaram o SVM e validaram o método de acordo com o protocolo AAMI e o esquema de divisão proposto por de Chazal et al. (2004). Estes mesmos autores utilizaram o SVM em uma configuração pseudo-hierárquica, para resolver o desbalanceamento da base de dados do MIT-BIH, e reportaram valores promissores. Em (de Lannoy et al., 2010), os autores conseguiram contornar o desbalanceamento da base de dados do MIT-BIH com SVM, alterando a função objetivo. Foram reportados ganhos expressivos nas classes SVEB e F.

Várias abordagens com variações do SVM vêm sendo propostas, como combinação da teoria fuzzy para aprimorar a classificação do SVM (Özcan e Gurgun, 2010), combinação de vários classificadores (*ensemble*) (Huang et al., 2010), algoritmos genéticos combinados ao SVM e com restrições fuzzy (Nasiri et al., 2009), *last square* SVM (Polat e Günes, 2007), entre outros.

Moavenian e Khorrami (2010) propuseram o uso de uma nova função kernel para o aprendizado do SVM. Foi utilizada uma mesma metodologia para comparar resultados obtidos entre SVM e MLP-ANN. O SVM foi mais eficiente com relação ao tempo, tanto para treino quanto para o teste. Já o MLP teve melhor desempenho em termos de acurácia/Se/+P/FPR.

### 3.4.2 ANN

Em (McCulloch e Pitts, 1943), um modelo computacional para o neurônio foi proposto. Pode-se pensar nas ANNs como sendo um sistema computacional contendo um grande número de neurônios artificiais. Estes neurônios podem ser vistos como processadores simples, massivamente paralelizados e organizados de forma inspirada a uma rede neuronal biológica.

Embora o modelo proposto em (McCulloch e Pitts, 1943) seja simplificado e não reflita o comportamento real de um neurônio biológico, com uma rede de neurônios artificiais podem-se realizar diversas tarefas, como por exemplo classificação de padrões, previsões, aproximação de funções, *etc.* Esses neurônios artificiais também podem ser generalizados para melhor atender às necessidades de um problema em específico, formando-se diversas arquiteturas de redes.

As arquiteturas mais utilizadas para classificação de arritmias são *Multilayer Perceptron* (MLP) e *Probabilistic Neural Network* (PNN). De acordo com Yu e Chen (2007) modelos construídos com PNN são mais robustos e eficientes computacionalmente que a tradicional MLP. Entretanto, em (Özbaya et al., 2006; Mehmet, 2004; Osowski e Linh, 2001) foi proposto uma rede híbrida neuro-fuzzy a fim de se minimizar os problemas da MLP, aumentando a generalização e reduzindo-se o tempo de treinamento.

Ince et al. (2009) apresentam um método para classificação de arritmias por meio de redes neuronais evolucionárias otimizadas com *particle swarm optimization* (PSO). Os autores relatam que os resultados obtidos foram melhores que os métodos estado-da-arte publicados até então. Todavia, o método não pode ser considerado completamente automático, pois ele necessita ser treinado (ou adaptado) com 5 minutos de batimentos específicos do paciente a ser diagnosticado. E então, estes 5 minutos precisam ser avaliados por um especialista.

Muitas outras abordagens foram propostas, como em (Güler e Übeyli, 2005), em que os autores utilizaram redes neuronais combinadas a fim de se conseguir um método mais genérico, a partir de uma forma mais sofisticada de validação cruzada. Entretanto, nos artigos revisados nesta dissertação de mestrado, apenas em (Mar et al., 2011) utilizou-se MLP com o esquema de divisão de pacientes proposto por de Chazal et al. (2004), o que impossibilita a comparação entre outros métodos que utilizaram redes neuronais. Mar et al. (2011) compararam MLP contra Discriminantes Lineares e constataram que o MLP foi significativamente superior.

A combinação de classificadores foi pouco explorada para a tarefa em questão. De acordo com Osowski et al. (2008), a combinação de classificadores pode não apenas reduzir o erro global das redes neuronais, mas também reduzir a incidência de falsos negativos.

### 3.4.3 Discriminantes Lineares

O método Discriminante Linear (LD) é um método estatístico baseado em funções discriminantes. As funções são estimadas a partir de um conjunto de dados, chamados conjunto de treino. Estas funções discriminantes são lineares com relação ao vetor de características e usualmente tem a forma,

$$f(x) = w^t x + b_0 \quad (3.3)$$

em que  $w$  representa o vetor de pesos,  $x$  o vetor de características e  $b_0$  um limiar.

Os critérios para o cálculo do vetor de pesos variam de acordo com o modelo adotado. Em (de Chazal et al., 2004), os parâmetros foram determinados por *maximum-likelihood* calculados a partir dos dados de treino.

Discriminantes lineares são os classificadores mais utilizados em métodos que seguiram o esquema proposto em (de Chazal et al., 2004) e as recomendações da AAMI. Esses autores alegaram que o classificador foi escolhido pela sua simplicidade e pelo fato de que eles não queriam enfatizar o classificador, mas sim as características propostas. Entretanto, o LD permite facilmente superar problemas gerados pelo desbalanceamento da base de treinamento, visto que quando se utiliza o esquema proposto em (de Chazal et al., 2004), obter valores promissores de classificação para as classes minoritárias (SVEB e VEB) torna-se um grande desafio (ver Tabela 2.7). Técnicas de balanceamento da base de dados de treinamento, que são pouco exploradas para este problema, podem ser estudadas em trabalhos futuros, como por exemplo, técnicas de amostragem mais sofisticadas como *Synthetic Minority Over-sampling Technique* (SMOTE) (Chawla et al., 2002).

### 3.4.4 Considerações Finais

Como poucos autores utilizaram um mesmo esquema de avaliação, como em (de Chazal et al., 2004; Llamedo e Martínez, 2011), é difícil realizar uma comparação justa entre classificadores. Todavia, a análise dos resultados produzidos por diferentes classificadores, seguindo-se um esquema de seleção de batimentos sem enviesamentos, pode ser uma via promissora para trabalhos futuros.

## Capítulo 4

# Um novo método para classificação de Arritmias

Este capítulo descreve um novo método hierárquico para classificação de arritmias a partir de sinais de ECG usando o algoritmo SVM (Cortes e Vapnik, 1995) em características morfológicas extraídas a partir de Vectorcardiograma (VCG) modelado como redes complexas (Watts e Strogatz, 1998) e temporais (intervalos de tempo). Além disso, um esquema de seleção de características é empregado.

A determinação de pontos importantes em um batimento cardíaco, ou segmentação, é um dos primeiros passos a ser realizado para a classificação de batimentos cardíacos e a técnica utilizada por para obtenção dos batimentos para este trabalho é brevemente discutida na Seção 4.1. Na Seção 4.2, as características utilizadas pelo método proposto para classificação são introduzidas de detalhadas. Pela primeira vez, redes complexas são usadas como características para classificação de arritmias a partir do VCG, visto que a aplicação de redes complexas tem mostrado resultados promissores em outras aplicações para descrição do contorno de formas Souza et al. (2011); Backes et al. (2009). Além dessas características, também propõe-se o uso de relativização de intervalos como RR e complexo QRS (anteriormente usavam-se somente os valores absolutos).

Neste trabalho, o uso de classificação hierárquica foi proposto devido à taxonomia existente entre os tipos de batimentos cardíacos como foi discutido anteriormente e apresentado na Tabela 2.1. Isto é, os diversos tipos de batimentos de cardíacos possuem uma hierarquia e podem ser vistos como uma estrutura em árvore. Um classificador chamado plano é um modelo para classificação em que as informações contidas nos níveis (nós) intermediários da árvore são desprezadas, ou seja, apenas os nós folha são considerados durante a construção do modelo. Grande parte dos modelos utilizados na literatura são classificadores planos. Os modelos de classificação hierárquica levam em consideração informações de todos os níveis da árvore. Este fato pode levar a um melhor desempenho na classificação de nós (classes) em níveis mais profundos da árvore. A Seção 4.3 é dedicada à tarefa de classificação.

Nesta dissertação, um algoritmo de seleção de características (busca para frente) baseado em uma abordagem *wrapper* usando análise de sensibilidade do SVM também foi executado a fim de se obter um menor subconjunto de características para gerar modelos de classificação com maior poder de generalização.

## 4.1 Segmentação

Como a etapa de segmentação não é o objetivo deste trabalho, nenhuma técnica automática proposta na literatura foi utilizada. O banco de dados de arritmia do MIT-BIH provê anotações de todos os eventos associados ao ECG e a informação temporal da ocorrência da onda R é um dos eventos. Essa informação é utilizada para segmentar um trecho de 256 amostras em torno da onda R, como ilustrado na Figura 4.1.




Figura 4.1: Segmento de um batimento normal do registro 100 do MIT-BIH.

Além do pré-processamento efetuado pelo *hardware* (sistema utilizado pelo MIT-BIH para amostragem do sinal), foi utilizado aqui a transformada Wavelet discreta (DWT) diretamente no sinal amostrado. Essa transformada foi utilizada com o propósito de ter uma representação mais compacta e menos redundante do final, além de também possibilitar redução do custo computacional das etapas posteriores devido à sub-amostragem<sup>1</sup> da transformada Wavelet.

<sup>1</sup>Processo em que o tamanho do sinal é reduzido pela metade.

## 4.2 Extração de características


A extração de características é o ponto chave em um sistema de classificação de batimentos cardíacos. Neste trabalho são utilizados vários tipos de características entre morfológicas e temporais. Características ainda não utilizadas para classificação de arritmias no sinal de ECG também são propostas. As novas características foram construídas a partir do intervalo RR e duração do complexo QRS “relativizados”<sup>2</sup> e, também, de redes complexas modeladas a partir do vectorcardiograma (VCG). Além dessas, a variância de autocorrelação de coeficientes wavelets também são usados. Nas próximas seções, estas características serão descritas.

### 4.2.1 Vectorcardiograma e Redes Complexas

A classificação dos batimentos categorizados como SVEB e VEB pode ser favorecida por informações provindas das derivações do tipo V1, V2 ou V4 (Goldberger et al., 2000). O VCG reúne informação de duas derivações simultaneamente e, por isso, características extraídas a partir dele podem ajudar a discriminar melhor as classes minoritárias, ou seja, SVEB e VEB.

Ao invés de se construir o VCG diretamente do sinal de ECG amostrado, foi feito um pré-processamento com DTW, como dito anteriormente, visando-se reduzir ruídos e simplificar a representação.

A transformada wavelet (WT) é um método eficiente para se representar sinais não estacionários, como sinais biomédicos. A WT pode ser vista como uma extensão da bem conhecida transformada de Fourier. Entretanto, diferentemente da transformada de Fourier, em que o sinal é decomposto em apenas uma “escala”, a WT pode transformar o sinal em múltiplas escalas e, em cada escala, informações particulares do sinal podem ser investigadas.



mesmo. As primeiras saídas, sub-amostradas, destes filtros formam os sinais chamados Detalhe e Aproximação do nível 1, respectivamente. Aplicando-se sucessivamente a transformada sobre o sinal de aproximação em um nível, obtém-se os outros sinais de detalhe e aproximação do próximo nível.

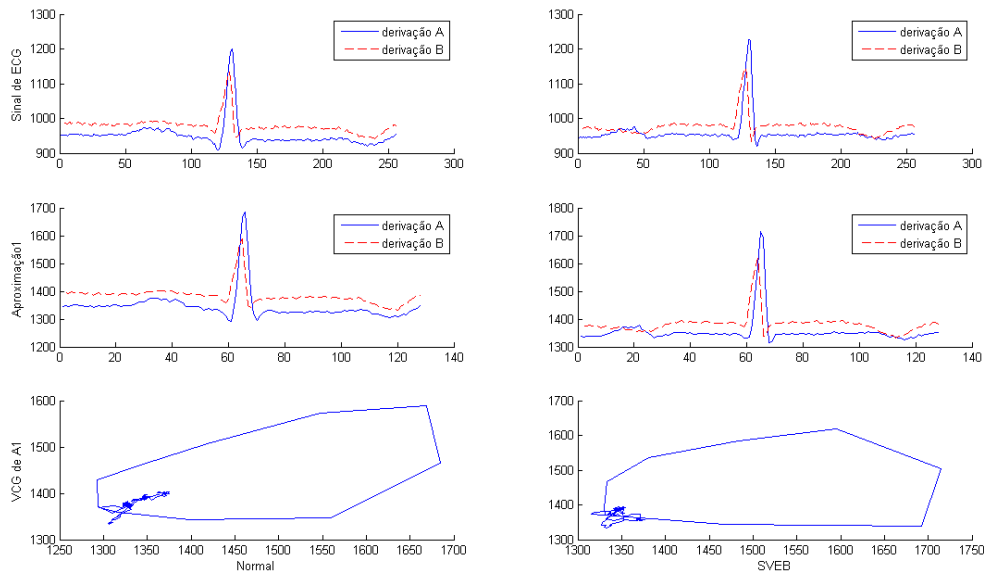


Figura 4.3: Ilustração do processo decomposição. Na primeira linha o sinal original do ECG, na segunda os coeficientes wavelets de aproximação do 1º. nível, e na terceira linha o VCG, para duas classes de batimentos: N e SVEB.

O vectorcardiograma foi construído a partir de coeficientes de aproximação do primeiro nível (A1) do sinal de ECG segmentado, ou seja, do batimento cardíaco decomposto. Para esta dissertação, resolveu-se efetuar o mesmo processo de construção do vectorcardiograma para a banda de detalhe do primeiro nível (D1) a fim de se investigar se existe informação relevante nas componentes de alta frequência. Estas sub-bandas foram escolhidas devido ao fato de conservarem boa parte da energia do complexo QRS.

O sinal de VCG é construído unindo-se duas derivações, no caso derivações A e B, em que a derivação A dá origem ao eixo das abcissas e a derivação B dá origem ao eixo das ordenadas. Assim, uma imagem em duas dimensões é gerada para cada batimento. Exemplos de VCG de um batimento normal e um arritmico (SVEB) podem ser vistos na Figura 4.3.

Para extrair características dessa representação bidimensional do VCG, que pode ser vista como um contorno de um objeto, utilizou-se redes complexas. O VCG foi modelado como um grafo, no qual cada ponto do VCG foi considerado um vértice do grafo. Observe que o VCG é um sinal finito, visto a natureza de discretização do sinal do ECG, e portanto o número de vértices do grafo também é finito. As seções subsequentes detalham este processo.

### Construção das Redes Complexas

A partir do VCG, descreve-se como modelar redes complexas, e então a obter/extrair características dessas redes. De acordo com Backes et al. (2009), o domínio de redes complexas pode ser visto como a interseção de duas outras importantes áreas, teoria dos grafos e estatística. Na literatura atual, podem-se encontrar aplicações de redes complexas nos mais diversos ramos da ciência da computação, como mostrado em (Antiqueira et al., 2007) e (Chalumeau et al., 2006), que utilizam modelagem usando redes complexas, abordando diversos problemas como correlação entre textos e discriminação de textura. Similarmente à (Backes et al., 2009; Souza et al., 2011), aplicam-se redes complexas para análise do contorno das formas.

A modelagem apresentada em (Backes et al., 2009) é baseada no modelo de rede Watts-Strogatz (Watts e Strogatz, 1998). Este modelo possui duas propriedades interessantes: 1) todos os vértices podem ser alcançados por qualquer outro com um número pequeno de arestas; 2) o grande número de ciclos mínimos (*e.g.*, tamanho 3) que eles são formados. Essas propriedades são definidas como propriedades de mundo pequeno. Adicionalmente, para extração de características, é necessário realizar uma evolução dinâmica que determina as arestas apresentadas nas redes complexas por um valor limiar incrementado dinamicamente. A construção e evolução das redes será detalhada nas subseções seguintes.

A fim de modelar a representação bidimensional do VCG como redes complexas, considera-se o conjunto de pontos  $C = [p_1, p_2, \dots, p_n]$ , em que  $p_i$  é um vetor de componentes  $[a_i, b_i]$  representando cada ponto pertencente às derivações A e B do VCG, em que  $a_i$  e  $b_i$  são suas coordenadas, respectivamente. Portanto, as redes será construída como um grafo no qual cada ponto  $p_i$  é um vértice e cada aresta tem peso determinado pela distância euclidiana entre seus vértices, *i.e.*,

$$d(p_i, p_j) = \sqrt{(a_i - a_j)^2 + (b_i - b_j)^2}. \quad (4.1)$$

Então obtém-se a matriz  $W$  de tamanho  $N_V \times N_V$  em que  $N_V$  representa o número de vértices da rede. A matriz é preenchida com os pesos das arestas calculados, *i.e.*,

$$w_{ij} = W([w_i, w_j]) = d(p_i, p_j), \quad (4.2)$$

para todo par  $(i, j)$  tal que  $1 \leq i, j \leq N_V$ .

Logo após, os valores da matriz são normalizados no intervalo  $[0, 1]$ , *i.e.*,

$$W'_{ij} = \frac{W_{ij}}{\max w_{ij} \in W}, \quad (4.3)$$

para todo par  $(i, j)$  tal que  $1 \leq i, j \leq N_V$ .

Dessa forma, a rede obtida é uma **rede regular**, pois cada vértice possui uma aresta para todos os outros (grafo completo). De uma rede regular não se pode extrair características interessantes para nossa abordagem, já que seus vértices têm o mesmo número de conexões, e



em essência é a partir deste número (*i.e.*, grau de conectividade dos vértices) que as medidas de redes são extraídas. Então, deve-se realizar uma transformação na rede de modo a se obter uma **rede complexa**. Essa transformação chamada de evolução dinâmica é descrita como o próximo passo para extração de características.

### Evolução Dinâmica

Como mostrado na seção anterior, o primeiro passo para o processo de extração de características é transformar a rede regular obtida em uma rede complexa. Então, um processo de evolução dinâmica de acordo com um limiar  $T_l$  é realizado. A transformação  $\delta$  é procedida como segue. A cada iteração  $l$ , todas as arestas com peso maior que  $T_l$  são removidas da rede regular. Então, obtém-se uma nova rede complexa a cada iteração  $l$ , *i.e.*,

$$A_{T_l} = \delta_{T_l}(W') = \begin{cases} a_{ij}(T_l) = 0, & \text{se } w'_{ij} \geq T_l \\ a_{ij}(T_l) = 1, & \text{se } w'_{ij} \leq T_l \end{cases}, \quad (4.4)$$

para todo par  $(i, j)$  tal que  $1 \leq i, j \leq N_V$ .

A evolução de cada rede é garantida pelo uso de várias funções  $\delta$  em que o limiar  $T_l$  é incrementado sequencialmente de um valor  $T_{inc}$ , *i.e.*,

$$\begin{aligned} T_0 &= T_0 | 0 < T_0 < 1, \\ T_{l+1} &= f(T_l) \text{ se } T_l < T_Q < 1, \\ f(x) &= x + T_{inc} \end{aligned} \quad (4.5)$$

em que  $T_0$  e  $T_Q$  são os limiares inicial e final, respectivamente,  $T_{inc} = (T_Q - T_0)/(n - 1)$  e  $n$  é o número finito de variações na rede complexa que define a sua evolução dinâmica. A escolha de  $T_0$  e  $T_Q$  é feita de forma empírica e é detalhada no Capítulo 5. A partir dessa evolução, *i.e.*, cada valor de  $T_l$ , extraem-se cinco características, a partir da *Conectividade* e do *Joint Degree* da rede complexa, como se segue.

### Conectividade

A conectividade  $k_i(T_l)$  de um vértice  $i$  corresponde ao número de arestas diretamente conectadas a esse vértice e pode ser obtida a partir da matriz de adjacência  $A_{T_l}$ , *i.e.*,

$$k_i(T_l) = \sum_{j=1}^N a_{ij}(T_l). \quad (4.6)$$

O primeiro conjunto de características extraído para posterior classificação é composto por descritores de **conectividade** presentes nas diversas transformações da rede  $T_l$ . Para cada rede complexa  $A_{T_l}$  obtida, dois valores descrevendo a conectividade de cada rede são

calculados, *i.e.*, o grau médio ( $k_\mu$ ) e o grau máximo ( $k_{max}$ ) de seus vértices, *i.e.*,

$$k_\mu(T_l) = \frac{1}{N} \sum_{j=1}^N a_{ij}(T_l), \quad (4.7)$$

$$k_{max}(T_l) = \max_i k_i(T_l). \quad (4.8)$$

Como demonstrado por Backes et al. (2009), apesar de essas características serem simples, pode-se torná-las invariantes à rotação e à escala com uso de pequenos ajustes. A invariância à rotação é obtida implicitamente devido a representação por grafos. Isto é, a localização de cada vértice não é levada em conta no cálculo das características. De outro lado, a invariância à escala pode ser alcançada pela normalização implementada na matriz  $W$  no intervalo  $[0, 1]$  e por uma consequente normalização de  $k_i$  pelo número de vértices ( $N$ ) que compõem a rede, *i.e.*,

$$\forall k'_i(T_l) = \frac{k_i(T_l)}{N} \quad (4.9)$$

Então o vetor de características  $\varphi_{CN}$ , *i.e.*,

$$\varphi_{CN} = [k_\mu(T_0), k_{max}(T_0), k_\mu(T_1), k_{max}(T_1), \dots, k_\mu(T_Q), k_{max}(T_Q)] \quad (4.10)$$

é formado pela concatenação dos valores de grau médio ( $k_\mu$ ) e grau máximo ( $k_{max}$ ) obtidos para cada estágio de evolução da rede utilizando limiares no intervalo  $[T_0, T_Q]$ .

### ***Joint Degree***

Além das duas características calculadas a partir da conectividade da rede complexa, *i.e.*, o grau médio ( $k_\mu$ ) e o grau máximo ( $k_{max}$ ), é possível extrair outras características das redes complexas utilizando a probabilidade conjunta dos graus dos vértices, *i.e.*, o *Joint degree*, que determina medidas de correlação entre os graus dos vértices.

Para determinar essas medidas a partir do *joint degree*, deve-se conhecer a distribuição de probabilidade  $P(k_i(T_l), k'(T_l))_i$ . Porém, no nosso método, considera-se  $k_i(T_l) = k'(T_l)$ , como sugerido em (Backes et al., 2009). Assim, a distribuição  $P(k_i(T_l), k_i(T_l))_i$  representa a probabilidade de um vértice  $i$  de grau  $k_i(T_l)$  estar conectado a outro vértice de mesmo grau. Essa distribuição pode ser calculada a partir do grau de todos os vértices. Dessa forma, é possível determinar a probabilidade de conexão entre um vértice de grau  $k_i(T_l)$  com outro  $k'(T_l)$  analisando a matriz de adjacência. Sendo assim, as características extraídas a partir do *joint degree* das redes complexas são entropia, energia e *joint degree* médio, *i.e.*,

- *Entropia*: De acordo com Backes et al. (2009), a entropia está diretamente relacionada ao grau de ordem ou de desordem em um sistema. O cálculo da entropia pode ser

definido como:

$$H(T_l) = - \sum_{i=1}^N P(k_i(T_l), k_i(T_l)) \log_2 P(k_i(T_l), k_i(T_l))_i. \quad (4.11)$$

- *Energia*: A energia pode ser definida pela seguinte expressão:

$$E(T_l) = - \sum_{i=1}^N (P(k_i(T_l), k_i(T_l))_i)^2. \quad (4.12)$$

- *Joint Degree Médio*: Essa medida denota a probabilidade média de encontrar dois vértices arbitrários de mesmo grau na rede, considerando todas as possibilidades

$$P(T_l) = \frac{1}{N} \sum_{i=1}^N P(k_i(T_l), k_i(T_l))_i. \quad (4.13)$$

Da mesma forma que em conectividade, o conjunto de características *joint degree* é formado pela concatenação dos valores de Energia ( $E$ ), Entropia ( $H$ ) e *Joint Degree* médio ( $P$ ) obtidos para cada estágio de evolução da rede utilizando limiares no intervalo  $[T_0, T_Q]$ , *i.e.*,

$$\varphi_{CNJD} = [E(T_0), H(T_0), P(T_0), E(T_1), H(T_1), P(T_1), \dots, E(T_Q), H(T_Q), P(T_Q)] \quad (4.14)$$

#### 4.2.2 Intervalo RR relativo e largura do complexo QRS relativo

A característica extraída do intervalo RR (intervalo de tempo entre os picos R e batimentos sucessivos) é amplamente encontrada em métodos que visam classificação de arritmias em sinal de ECG. A forma mais comum de características extraídas do intervalo RR encontrada na literatura é o intervalo de tempo absoluto entre o pico corrente e seu antecessor. Todavia, pacientes diferentes possuem diferentes frequências cardíacas. Embora pessoas tendam a ter, em média, frequências parecidas, este parâmetro pode variar muito com a idade ou condições físicas. Calcular esta característica com relação ao intervalo RR médio de cada paciente pode torná-la mais robusta a estas variações.

Aqui, neste trabalho, propõe-se que o intervalo RR seja definido pela seguinte equação:

$$RR \text{ relativo} = \frac{RR(i) - RR(i-1)}{RR_{medio}} \quad (4.15)$$

em que  $RR(i) - RR(i-1)$  é o intervalo de tempo entre o batimento atual  $i$  e seu antecessor  $i-1$  e  $RR_{medio}$  é calculado pela média dos  $n$  batimentos ao redor do batimento corrente<sup>3</sup>.

<sup>3</sup>Acompanhando o que foi utilizado na literatura, usou-se  $n = 10$ .

Para este trabalho, propõem-se duas informações de *RR relativo*, o RR prévio (intervalo entre o pico corrente e seu antecessor) e RR posterior (intervalo entre o pico posterior e o corrente).

O batimento cardíaco pode ser dividido em vários segmentos, como por exemplo os bem conhecidos segmentos ST e complexo QRS. Também propõe-se o uso da duração do complexo QRS relativizado, conforme feito com o intervalo RR. Esta característica foi proposta visando melhorar o desempenho da classificação da classe SVEB, visto que ela é composta basicamente pelos batimentos do tipo *Atrial premature beat* (A). Este tipo de batimento pode ocasionar deformações conhecidas na morfologia do batimento, como complexo QRS com largura mais estreita, onda P pequena ou ausente ou até mesmo a presença da onda P após a contração do ventrículo.

Para a determinação dos pontos fiduciais que compõem o complexo QRS (pontos Q, R e S), neste trabalho, foi utilizado o algoritmo proposto em (Laguna et al., 1994). O algoritmo é especializado em determinar pontos fiduciais no banco de dados de arritmias do MIT-BIH e faz uso das anotações fornecidas pelo banco.

#### 4.2.3 Variância da função de autocorrelação

Somado às características provindas do VCG e redes complexas, intervalo RR relativo e duração do complexo QRS relativo, são acrescentadas três características calculadas da variância da função de autocorrelação das bandas A2, D2 e D1 da WT do batimento cardíaco da derivação A. A variância da função de autocorrelação já foi utilizada anteriormente como característica para este tipo de aplicação (Yu e Chen, 2007) e se mostrou bem eficiente para discriminar batimentos arrítmicos.

A função de autocorrelação é uma técnica utilizada para se encontrar padrões repetitivos em sinais. Ela é considerada uma medida de similaridade ou coerência entre um sinal  $x(n)$  e sua versão deslocada. A função de autocorrelação de  $x$  em função do deslocamento  $l$  pode ser expressa por

$$AC_x(l) = \sum_{n=i}^{N-|k|-1} x(n)x(n-l) \quad (4.16)$$

em que  $N$  é o comprimento de  $x$ ,  $i = l$ ,  $k = 0$  para  $l \geq 0$  e  $i = 0$ ,  $k = l$  para  $l < 0$ . Nos experimentos, usou-se  $l = 1$  como sugerido em (Yu e Chen, 2007).

#### 4.2.4 O vetor de características

Nesta seção foram descritas as características que compõem o vetor de características que será utilizado no processo de classificação de cada batimento cardíaco. Elas são sumarizadas a seguir.

- Morfológicas

- Redes Complexas modeladas a partir do VCG
  - \* Conectividade: Grau médio (1) e máximo (2)
  - \* *Joint Degree*: Energia (3), Entropia (4) e *Joint Degree Médio* (5)
- Variância da Autocorrelação (6,7,8)
- Temporais
  - Intervalos RR anterior (9) e posterior (10)
  - Duração do Complexo QRS (11)

Observe que a princípio têm-se somente 11 características, mas esse tamanho pode variar dependendo de parâmetros. A partir do VCG e redes complexas, têm-se 5 características para cada limiar  $T_l$  de evolução dinâmica. A quantidade de limiares  $T_l$  é definido dependendo dos valores de  $T_0$ ,  $T_Q$  e  $T_{inc}$  como já descrito na Equação 4.5. E segundo a teoria de redes complexas (Watts e Strogatz, 1998), a partir de dois limiares é que se pode estudar o comportamento da evolução das redes. Além disso, propõe-se estudar VCGs extraídos a partir de coeficientes de aproximação e detalhe do primeiro nível de decomposição Wavelet do sinal de ECG, *i.e.*, A1 e D1. No Capítulo 5, experimentos serão realizados para determinar os valores de  $T_l$  a serem utilizados. Para a variância de autocorrelação, propõe-se estudar 3 conjuntos de coeficientes, *i.e.*, A2, D2 e D1.

Na próxima seção, a hierarquização da classificação é apresentada.

### 4.3 Classificação

Uma vez que as características são extraídas, é necessário discriminar as classes de batimentos cardíacos. Para essa função, escolheu-se o algoritmo *Support Vector Machines* (SVM) (Cortes e Vapnik, 1995). SVMs são métodos que constroem classificadores a partir da criação de hiper-planos em um espaço dimensional maior (Scholkopf e Smola, 2002) que o original, *i.e.*, de forma a se obter uma separação linear dos dados.

O SVM é um dos classificadores mais populares encontrados na literatura para classificação de arritmias em sinais de ECG (Song et al., 2005; Ye et al., 2010; Parlitz et al., 2011; Asl et al., 2008; Yu e Chou, 2009). Com o SVM, pode-se compensar o desbalanceamento da base de treinamento por meio de parâmetros, tornando-o ainda mais atrativo para a classificação de arritmias em que o desbalanceamento entre as classes é grande.

Ainda, quando se utiliza o esquema de validação proposto em (de Chazal et al., 2004) que não permite que batimentos de um mesmo registro de paciente esteja presente nos conjuntos de treino e de teste, lidar com o problema de balanceamento se torna um desafio, pois os algoritmos de classificação não podem contar com particularidades dos batimentos de um paciente para classificá-los.

Como discutido na Seção 2.4.1, a abordagem escolhida de classificação hierárquica foi a LCPN. Normalmente, para o LCPN, o mesmo algoritmo para classificação é utilizado para toda hierarquia de classes, embora, propostas de uso de classificadores diferentes para cada nó pai já foram apresentadas com sucesso. A classificação de arritmias também pode ser beneficiada com o uso de classificadores, ou conjunto de características diferentes nos diversos níveis da classificação hierárquica. Neste trabalho, em particular, usar-se-á o SVM em ambos os níveis de hierarquia. Todavia, propõe-se testar diferentes conjuntos de características para cada nível. Estes detalhes serão discutidos no Capítulo 5.

Então, propõe-se o uso de dois classificadores em dois níveis diferentes, como ilustra a Figura 2.3: Nível 1 - um classificador para as classes de batimentos normal e arritmico; Nível 2 - um classificador para as classes de batimentos SVEB, VEB, e F.

## 4.4 Seleção de Características

Conjuntos de características de diversos tamanhos podem ser extraídos com a metodologia proposta na Seção 4.2.1, que envolve VCG e redes complexas, dependendo do número de iterações utilizadas para a construção da rede complexa, *i.e.*, valor de  $n$  que determina a quantidade de limiares  $T_l$ . Todavia, modelos de classificação construídos com poucas características podem ter maior poder de generalização em dados não vistos (conjunto de teste). E também podem ter um custo computacional menor para aprendizado e classificação considerando a menor dimensionalidade da representação.

Normalmente, abordagens de seleção de características presentes na literatura podem ser classificadas em duas categorias: abordagens *filter* e *wrapper*. Abordagens *filters* são independentes do algoritmo de aprendizado utilizado no processo de classificação, enquanto que abordagens *wrappers* exploram o conhecimento da estrutura específica do algoritmo de aprendizado e não podem ser separadas dele. Geralmente, abordagens *wrapper* costumam fornecer resultados melhores, mas a um custo computacional às vezes impraticável.

A solução adotada por este trabalho foi usar uma abordagem *wrapper* que usa a análise de sensibilidade do SVM (Shen et al., 2008; Gutiérrez e Hadi, 1997; Guyon e Elisseeff, 2003) combinada com um algoritmo de busca para frente, que parte de um conjunto mínimo de características e vai adicionando novas se um determinado critério relacionado com a acurácia da classificação é melhorado.

A análise de sensibilidade em seleção de características que é proposta procura medir o quão sensível um classificador é com relação à ausência de uma característica. Todavia, não se deseja remover fisicamente a característica do conjunto e treinar novamente o classificador para realização dos testes, como seria uma abordagem puramente *wrapper*. O que se propõe fazer para evitar a remoção física da característica e consequente retreinamento do classificador, é utilizar o valor médio daquela característica obtido a partir da base de treinamento para

então utilizá-lo no momento do uso do classificador no teste quando essa característica não estará logicamente presente no conjunto selecionado. Dessa forma, evita-se a criação de novos modelos para a avaliação de um subconjunto de características.

O uso da análise de sensibilidade do SVM está intimamente ligado com o custo computacional de avaliação de cada subconjunto de características. Considerando um espaço de busca combinatorial e exponencial, a ser percorrido por um algoritmo de busca de força bruta, o tempo necessário para realizá-la tornaria a busca intratável. Mesmo se fosse considerado um espaço mais restrito e sub-ótimo, como por exemplo de ordem quadrático que é o caso do espaço investigado por algoritmos gulosos de busca para frente e para trás (o primeiro usado neste trabalho), o tempo de execução se tornaria proibitivo, *i.e.*, demandaria meses, se a análise de sensibilidade não fosse utilizada.

Neste trabalho, a avaliação de cada subconjunto de características é feita usando-se um esquema de validação cruzada com  $k$  folds, em que  $k$  é o número de registros/pacientes envolvidos. Para cada novo subconjunto de características a ser testado, deveriam ser construídos (treinados)  $k$  modelos, caso uma abordagem puramente *wrapper* fosse empregado. Todavia com o emprego da análise de sensibilidade proposta, basta que os modelos já construídos sejam testados, usando-se o valor médio (obtido no treinamento) daquelas características que estão fora do subconjunto a ser avaliado. Essa abordagem diminui significativamente o tempo de execução para avaliação de cada subconjunto de características.

O algoritmo de busca para frente para seleção de características é guloso e funciona da seguinte forma. Dado um subconjunto de características (possivelmente vazio), procura-se dentre as características disponíveis (fora do subconjunto) qual é aquela que se adicionada ao subconjunto atual fornecerá a melhor função objetivo/critério. A melhor característica disponível naquele determinado instante é então adicionada ao subconjunto e o algoritmo continua sua execução até que não se obtenha mais melhoria na função objetivo ou até que um determinado critério de parada seja alcançado.

Obviamente que esta estratégia quase sempre não leva ao conjunto ótimo - aquele com a melhor função objetivo, visto a natureza combinatória do problema. Todavia, o emprego desse algoritmo para esta tarefa é executado em tempo tratável e resultados promissores têm sido alcançados por algoritmos similares (Mar et al., 2011).

Como função objetivo ou critério, utiliza-se a acurácia ponderada das classes envolvidas pelo inverso do número de amostras de cada classe na base de treinamento, *i.e.*,

$$Acc. \text{ Ponderada} = \frac{Acc(C_1)}{w_{C_1}} + \frac{Acc(C_2)}{w_{C_2}} + \dots + \frac{Acc(C_N)}{w_{C_s}} \quad (4.17)$$

em que  $Acc(C_i)$  e  $w_{C_i}$  significam a acurácia e o número de amostras da classe  $i$ , respectivamente, com  $1 \leq i \leq s$ , e  $s$  é o número de classes. Propõe-se utilizar a ponderação pelo número de amostras de cada classe para obter-se um equilíbrio na classificação de cada classe e não otimizar a acurácia global que pode ser enviesada pela classe  $N$ , que é predominante.

---

**Algoritmo 4.1:** Algoritmo de sensibilidade e busca para frente

---

**Data:** *DSU* - Partição de treino**Data:** *VMODEL* - Modelos do classificador para os 22 registros de *DSU***Result:** *FS* - Características selecionadas

```

/* Inicialização */
FS ← ∅

/* Seleção */
for i ← 1 ; i ≤ número de atributos ; i ++ do
    for j ← 1 ; j ≤ número de atributos ; j ++ do
        if j ∉ FS then
            for k ∈ Registro de Pacientes do
                Use VMODEL[k] para testar os batimentos de k
                Computar VCRIT[j][k]
            VCRIT_CARAC[j] ← media(VCRIT[j][k])
        /* Calcula a avaliação média e encontra a configuração que maximiza o
           resultado */
        [VCRIT_MAX, l] ← max(VCRIT_CARAC(l))
        if VCRIT_MAX > BEST_CRIT_VALUE then
            BEST_CRIT_VALUE ← VCRIT_MAX
            FS ← FS ∪ {l}
        else
            break
return FS

```

---

Então, como essa técnica é gulosa, o algoritmo escolhe, a cada iteração, a configuração que resultou na maior acurácia ponderada. Salienta-se que esse algoritmo de seleção de características é executado para os dois níveis de classificação hierárquica, de forma que a seleção é feita separadamente para cada classificador.

O Algoritmo 4.1 descreve mais precisamente como o processo de seleção de características é realizado.



## Capítulo 5

# Resultados Experimentais

A avaliação do método proposto é apresentada neste capítulo. Para realização da avaliação, foram levadas em conta as recomendações da AAMI, o banco de dados do MIT-BIH (Massachusetts Institute of Technology, 2011) e o esquema de divisão de batimentos para treino e teste dos modelos proposto em (de Chazal et al., 2004). Muitos detalhes sobre esse *setup* são lembrados na Seção 5.1, pois já foram apresentados no Capítulo 2. Os parâmetros para a construção das redes complexas foram determinados pelos experimentos apresentados na Seção 5.2.1 e um modelo de inicial para a etapa de classificação dos batimentos do ECG foi escolhido. Variações deste modelo inicial foram construídas usando-se diferentes subconjuntos de combinações de características: intervalos RR e duração do complexo QRS e seleção de características das redes complexas extraídas a partir do VCG (Seção 5.2.2.1). A análise e escolha do melhor modelo será realizada na Seção 5.2.2 e os testes serão apresentados na Seção 5.2.4. Experimentos adicionais foram feitos levando-se em conta uma variação da norma AAMI que considera apenas 3 classes de arritmias, proposta por Llamedo e Martínez (2011), chamada AAMI2 (Seção 5.3).

### 5.1 Características da base de dados

Neste trabalho, o banco de dados de arritmia do MIT-BIH foi utilizado para treinamento e avaliação dos modelos propostos. Para facilitar a leitura do documento, algumas informações divulgadas nas Seções 2.1 e 2.2 são novamente apresentadas aqui, porém de forma breve.

Este banco é recomendado pela norma ANSI/AAMI EC57:1998/(R)2008 (ANSI/AAMI, 2008), que padroniza o relatório de resultados fornecidos por algoritmos destinados à classificação de arritmias. O banco contém 48 registros de aproximadamente 30 minutos de batimentos, amostrados a 360Hz de duas derivações<sup>1</sup>, pertencentes a 47 pacientes diferentes. Os batimentos são divididos em 15 categorias (classes). A norma recomenda que essas 15 classes sejam

---

<sup>1</sup>Nem todos os registros utilizam as mesmas derivações, mas no geral utiliza-se a derivação II e V1.

agrupadas em 5 classes: 1) *normal beat*; 2) *ventricular ectopic beat* (VEB); 3) *supraventricular ectopic beat* (SVEB); 4) *fusion of a VEB and a normal beat*; and 5) *unknown beat type*, como visto na Tabela 2.1. A norma também recomenda a exclusão de 4 pacientes contendo marca-passo.

Não compete à norma AAMI especificar quais pacientes/batimentos devem ser utilizados para treino e teste, contudo o esquema de divisão proposto em (de Chazal et al., 2004) foi adotado por este trabalho para fins de comparação, já que o mesmo tem o cuidado de não misturar batimentos dos mesmos pacientes para os conjuntos de treino e teste (de Chazal et al., 2004; Ince et al., 2009; Luz e Menotti, 2011a)<sup>2</sup>.

Os dois conjuntos de registros de batimentos que são propostos em (de Chazal et al., 2004), **DS1** (para treinamento) e **DS2** (para teste), e suas distribuições de batimentos por paciente, podem ser vistos na Tabela 5.1. Para os experimentos, apenas o primeiro e o último batimento de cada registro foram descartados, pois algumas características não poderiam ser extraídas para estes batimentos, como por exemplo o intervalo RR anterior e posterior, além do que estes batimentos podem conter algum ruído do processo de aquisição. É importante observar que este descarte também é adotado por outros trabalhos da literatura (de Chazal et al., 2004; Llamado e Martínez, 2011). Apesar de listarmos a distribuição da classe Q, ela foi descartada por ser muito pouco representativa como sugere Llamado e Martínez (2011), visto que têm-se apenas 15 batimentos dessa classe, 8 em DS1 e 7 em DS2.

As medidas recomendadas pela AAMI para avaliação dos métodos utilizadas neste trabalho são *Sensitivity* (*Se*), *Positive Predictivity* (*+P*), *False Positive Rate* (*FPR*) e Acurácia Global (*Acc*), e foram apresentadas na Seção 2.1.

## 5.2 Experimentos

Os experimentos realizados neste trabalho foram divididos em três etapas: definição dos parâmetros da rede complexa para escolha do modelo inicial; escolha do melhor modelo dentre os vários criados a partir do modelo inicial; e validação do modelo escolhido na partição de teste. Observe que as duas primeiras etapas são executadas usando-se DS1, e a última DS2. A implementação do método proposto foi feita em Matlab<sup>3</sup> e usou-se a bem conhecida biblioteca LibSVM (Chang e Lin, 2011) para execução do algoritmo SVM.

### 5.2.1 Parâmetros para extração de características com VCG e redes complexas

Com os sinais de duas derivações de um batimento cardíaco é possível criar uma figura em duas dimensões. Cada ponto da figura gerada (VCG) é utilizado para a construção do grafo

<sup>2</sup>Com exceção dos registros 201 e 202 que são do mesmo paciente e estão em conjuntos diferentes.

<sup>3</sup>O código fonte está disponível em <http://code.google.com/p/arrhythmia-paper/>, último acesso em 01/02/2012

Tabela 5.1: Distribuição de batimentos por registro da base de dados MIT-BIH (Massachusetts Institute of Technology, 2011). Os registros selecionados por de Chazal et al. (2004) como sendo DS1 estão em **negrito**.

Registro	N	SVEB	VEB	F	Q	Total
<b>101</b>	1859	3	0	0	2	1864
<b>106</b>	1506	0	520	0	0	2026
<b>108</b>	1739	4	17	2	0	1762
<b>109</b>	2491	0	38	2	0	2531
<b>112</b>	2536	2	0	0	0	2538
<b>114</b>	1819	12	43	4	0	1878
<b>115</b>	1952	0	0	0	0	1952
<b>116</b>	2301	1	109	0	0	2411
<b>118</b>	2165	96	16	0	0	2277
<b>119</b>	1542	0	444	0	0	1986
<b>122</b>	2475	0	0	0	0	2475
<b>124</b>	1535	31	47	5	0	1618
<b>201</b>	1634	128	198	2	0	1962
<b>203</b>	2528	2	444	1	4	2979
<b>205</b>	2570	3	71	11	0	2655
<b>207</b>	1543	106	210	0	0	1859
<b>208</b>	1585	2	992	373	2	2954
<b>209</b>	2620	383	1	0	0	3004
<b>215</b>	3194	3	164	1	0	3362
<b>220</b>	1952	94	0	0	0	2046
<b>223</b>	2044	73	473	14	0	2604
<b>230</b>	2254	0	1	0	0	2255
100	2238	33	1	0	0	2272
103	2081	2	0	0	0	2083
105	2525	0	41	0	5	2571
111	2122	0	1	0	0	2123
113	1788	6	0	0	0	1794
117	1533	1	0	0	0	1534
121	1860	1	1	0	0	1862
123	1514	0	3	0	0	1517
200	1742	30	826	2	0	2600
202	2060	55	19	1	0	2135
210	2422	22	195	10	0	2649
212	2747	0	0	0	0	2747
213	2640	28	220	362	0	3250
214	2002	0	256	1	2	2261
219	2081	7	64	1	0	2153
221	2030	0	396	0	0	2426
222	2273	209	0	0	0	2482
228	1687	3	362	0	0	2052
231	1567	1	2	0	0	1570
232	398	1381	0	0	0	1779
233	2229	7	831	11	0	3078
234	2699	50	3	0	0	2752
<b>DS1</b>	45844	943	3788	415	8	50998
DS2	44238	1836	3221	388	7	49690
<b>TOTAL</b>	90082	2779	7009	803	15	100688

Tabela 5.2: Avaliação de parâmetros para extração de características de redes complexas a partir do VCG usando os coeficientes Wavelet A1 e D1 e validação cruzada 22-*folds* em DS1. O valor de  $T_0$  é igual a 0,05 para todos os casos.  $Acc1$  e  $Acc2$  são as acurácias de classificação no primeiro e segundo níveis, respectivamente.

$n$	$T_Q$	$Acc1$	N			Arr			$Acc2$	SVEB			VEB			F		
			$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$		$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$	$Se/+P/FPR$
2	0,3	89,1	90,6	97,1	24,1	75,9	47,5	9,4	90,9	50,6	54,7	4,0	96,1	95,2	54,2	0,0	—	0,0
2	0,6	88,6	90,1	97,0	24,6	75,4	46,1	9,9	88,2	36,8	39,6	4,7	95,1	94,8	68,8	1,1	5,6	0,4
2	0,9	85,5	86,5	96,9	24,2	75,8	38,8	13,5	89,4	48,7	40,6	6,2	94,0	95,5	54,4	0,0	—	0,0
4	0,3	87,4	88,8	96,9	25,0	75,0	42,9	11,2	90,9	48,1	55,3	3,5	96,3	95,4	57,6	0,0	0,0	0,3
4	0,6	86,3	87,5	97,0	24,0	76,0	40,5	12,5	88,9	33,1	49,0	2,9	96,8	94,3	74,2	0,0	0,0	0,3
4	0,9	87,8	89,2	97,0	24,3	75,7	44,0	10,8	87,1	19,5	35,0	2,9	95,4	93,6	81,8	3,0	4,2	1,8
6	0,3	86,7	87,7	97,2	22,9	77,1	41,5	12,3	88,8	28,2	40,3	3,9	96,0	93,5	72,2	7,3	25,0	0,3
6	0,6	86,2	86,9	97,5	20,1	79,9	40,6	13,1	83,1	25,8	28,3	7,6	94,0	92,1	62,4	1,3	4,5	1,1
6	0,9	83,3	84,1	97,0	23,3	76,7	35,1	15,9	87,4	31,4	58,3	1,9	96,1	94,6	74,0	0,7	1,1	2,4

completo, que após sucessivas evoluções (remoção de arestas com base em um critério) dá se o nome de rede complexa.

Desta forma, para cada evolução ou iteração haverá 5 características extraídas da rede complexa, para cada banda Wavelet. Podem-se obter vários modelos para extração de características, variando-se os parâmetros  $T_0$ ,  $T_Q$  e o número de evoluções ( $n$ ). Para o método em questão, a escolha dos parâmetros foi realizada com base em vários experimentos na partição de treino (DS1), com um esquema de validação cruzada 22-*folds*, em que cada *fold* contém batimentos de um único registro (paciente)<sup>4</sup>. Segundo a Tabela 5.2, a melhor configuração foi obtida com  $n = 2$ ,  $T_0 = 0,05$  e  $T_Q = 0,3$ , o que totaliza 20 características extraídas do VCG, somadas às outras 6 características já mencionadas: duas do intervalo RR, uma da duração do complexo QRS e três características extraídas com a função de autocorrelação. Observe que apesar dos valores das medidas serem os melhores dentre quase todas as configurações, esta foi escolhida pois resulta em um menor conjunto de características. Isto é, quando  $n = 4$  ou  $n = 6$  o conjunto que tem 20 características para  $n = 2$ , passaria para 40 ou 60 características, respectivamente. É importante destacar que  $T_0 = 0,05$  foi mantido fixo para não termos uma grande quantidade de resultados a serem analisados e também porque em outros trabalhos relacionados com redes complexas este valor foi sugerido Souza et al. (2011); Backes et al. (2009).

Observe também que os valores reportados na Tabela 5.2 para as classes SVEB, VEB e F são aqueles obtidos pela classificação do segundo nível, exclusivamente. Para se obter os valores finais das medidas para estas classes deve se considerar somente o percentual de batimentos classificados como arritmicos no primeiro nível.

<sup>4</sup>22-*folds* pois em DS1 temos 22 registros de batimentos de pacientes

### 5.2.2 Escolha do melhor modelo

Neste trabalho, têm-se 26 características para a construção do modelo hierárquico com SVM, ou seja, para se construir dois classificadores: um para discriminar entre duas classes, Normal e Arritmica; e um outro classificador para discriminar os batimentos dentre os arrítmicos (SVEB, VEB e F).

Inicialmente, três classificadores foram construídos. Dois para a classificação hierárquica e um para classificação plana, para fins de comparação. Os parâmetros do SVM foram escolhidos de forma a se obter um modelo de classificação com maior poder de generalização em batimentos não vistos. Assim, nesta primeira fase, os parâmetros do SVM foram fixados em  $C = 0,5$  e  $\gamma = \frac{1}{8 \times \text{numero de características}}$ , em que o parâmetro  $C$  está relacionado com a função objetivo (regula a *soft margin*) e  $\gamma$  é um parâmetro da função *kernel* utilizada nestes experimentos, ou seja, a *radial basis function* (RBF)<sup>5</sup>.

Para contornar o desbalanceamento das classes, foram utilizados “pesos” diferentes para cada classe ( $w$ ). Estes pesos são multiplicadores do parâmetro  $C$  e foram definidos de forma inversamente proporcional ao número de instâncias de cada classe. Para o classificador plano, os valores dos pesos foram:  $w_1 = 1$ ,  $w_2 = 50$ ,  $w_3 = 10$  e  $w_4 = 50$ , que são pesos referentes às classes N, SVEB, VEB e F, respectivamente. Já para classificação hierárquica, pesos diferentes foram utilizados para cada um dos classificadores, de forma que no classificador do primeiro nível utilizaram-se  $w_1 = 1$  e  $w_2 = 10$ , para as classes normal e arritmica, respectivamente, e para o classificador do segundo nível utilizaram-se  $w_1 = 3$ ,  $w_2 = 1$ ,  $w_3 = 3$ , para as classes SVEB, VEB e F, respectivamente. Ressalta-se que a não utilização destes pesos levaria à resultados em que o classificador prediria/classificaria todos os dados não vistos como sendo pertencentes à classe majoritária, isto é, a classe N.

A partir desses 3 classificadores SVMs, dois modelos foram construídos: classificação plana e classificação hierárquica. Ambos foram construídos utilizando-se as 26 características disponíveis. Os modelos e classificadores foram construídos usando-se DS1 em um esquema de validação cruzada por paciente (ou registro) com  $k$ -folds e  $k = 22$ , em que cada *fold* representa batimentos de apenas um paciente. Os resultados obtidos por esses classificadores podem ser vistos na Tabela 5.3. Pode-se perceber que a acurácia global obtida com o modelo hierárquico é significativamente maior que a acurácia obtida com o modelo plano. Observe o aumento da *Se* da classe Normal no modelo hierárquico quando comparado ao modelo plano. A classe SVEB também se beneficiou do uso de classificação hierárquica, especialmente com relação à  $+P$  e  $FPR$ , com leve queda na  $+P$  da classe VEB.

Contudo, modelos de dimensionalidade menor geralmente podem possuir maior poder de generalização e costumam obter um melhor desempenho durante o teste, visto que os modelos gerados são menos complexos e menos amostras são necessárias para o treinamento. Assim, algumas técnicas foram experimentadas, como seleção de características usando-se busca para

<sup>5</sup>Usou-se um *script* (Kernel Machines (2012)) que realiza uma busca *grid* para obter estes valores.

Tabela 5.3: Desempenho dos modelos plano e hierárquico em DS1 usando 26 características e validação cruzada 22-*folds* (pacientes/registros).

Tipo de classificação	$Acc$	N			SVEB			VEB			F		
		$Se$	$+P$	$FPR$	$Se$	$+P$	$FPR$	$Se$	$+P$	$FPR$	$Se$	$+P$	$FPR$
Plana	77.6	79.3	97.1	21.1	31.8	3.8	15.2	76.8	52.2	5.8	0.0	0.0	0.0
Hierárquica	88.5	90.0	96.9	25.5	31.8	29.3	0.2	72.6	43.5	5.9	0.0	0.0	0.0

frente e análise de sensibilidade do SVM (apresentado na Seção 4.4) para criação de novos modelos com espaço de características reduzidos.

Detalhes sobre o uso dessas técnicas podem ser vistos no restante desta subseção.

#### 5.2.2.1 Busca para frente e análise de sensibilidade

Um esquema de seleção de características baseado em busca para frente e análise de sensibilidade do SVM foi utilizado em DS1, conforme apresentado na Seção 4.4. O objetivo de usar-se esta processo de seleção é obter um conjunto mais coeso de características e que também permita obter melhor eficácia para os modelos treinados. Este esquema foi utilizado em três configurações distintas. Para o modelo de classificação plana (Plano), e para os níveis hierárquicos separadamente. As características selecionadas para cada modelo podem ser vistas na Tabela 5.4.

A seleção de características foi feita apenas no conjunto de características extraídos das redes complexas a partir do VCG. Para o algoritmo da busca para frente, partiu-se de uma pré-seleção contendo as características do intervalo RR, complexo QRS e as três características extraídas com a função de autocorrelação, visto que estas características são consideradas essenciais em processos de classificação de arritmias (Llamedo e Martínez, 2011).

Como algumas características extraídas das redes complexas a partir do VCG ofereceram ganhos aos modelos de classificação hierárquica e plana, elas foram então consideradas. Como pode ser observado pela Tabela 5.4, o grau de entropia ( $H$ ) calculado a partir da rede complexa formada pelo VCG da banda A1 foi a única característica comum aos três modelos.

#### 5.2.3 Análise dos modelos

A eficácia dos modelos descritos na subseção anterior usando esquema de validação cruzada 22-*folds* em DS1 pode ser visto na Tabela 5.5. O resultado obtido pela classificação plana com seleção de características apresenta ganhos claros para as classe N, SVEB e VEB, se comparado ao resultado obtido com classificação plana sem seleção de características. No entanto, esse resultado ainda é inferior aos obtidos por classificação hierárquica, exceto para a classe VEB. Ainda, observando-se os valores das medidas na Tabela 5.5, constata-se que os modelos hierárquicos com e sem seleção de características tiveram desempenho bem próximos.

Tabela 5.4: Características selecionadas para 3 modelos: Modelo de classificação plana (Plano), primeiro nível hierárquico (Hierárquico 1) e segundo nível hierárquico (Hierárquico 2). Observe que os dados referente as 26 características estão separados em duas subtabelas por motivo de espaço.  $CN(VCG(WT - A1))$  está para modelagem de redes complexas obtidas a partir do VCG que por sua vez foi obtido a partir dos coeficientes Wavelet de aproximação do primeiro nível de decomposição, bem como  $var(AC(x))$  está para a variância dos coeficientes de auto-correlação do sinal original do ECG.

Classificador	Intervalo RR		$CN(VCG(WT - A1))$ com $T_l = 0,05$					$CN(VCG(WT - A1))$ com $T_l = 0,30$				
	prev	pos	$k_\mu$	$k_{max}$	H	E	P	$k_\mu$	$k_{max}$	H	E	P
Hierárquico 1	x	x	-	-	x	-	-	-	-	x	-	-
Hierárquico 2	x	x	-	-	x	-	x	-	-	x	-	x
Plano	x	x	x	-	x	x	-	-	-	x	-	-

Classificador	$CN(VCG(WT - D1))$ com $T_l = 0,05$					$CN(VCG(WT - D1))$ com $T_l = 0,30$					var(AC(x))			largura
	$k_\mu$	$k_{max}$	H	E	P	$k_\mu$	$k_{max}$	H	E	P	D1	D2	A2	QRS
Hierárquico 1	x	-	-	-	-	-	-	-	-	-	x	x	x	x
Hierárquico 2	x	x	-	-	-	-	-	-	-	-	x	x	x	x
Plano	-	-	-	-	-	-	x	-	x	-	x	x	x	x

Tabela 5.5: Desempenho dos modelos variando o conjunto de características: total (26 características) e seleção de características (SC).

Tipo de classificação	Acc	N			SVEB			VEB			F		
		Se	+P	FPR	Se	+P	FPR	Se	+P	FPR	Se	+P	FPR
Plana (26 características)	77.6	79.3	97.1	21.1	31.8	3.8	15.2	76.8	52.2	5.8	0.0	0.0	0.0
Hierárquica (26 características)	88.5	90.0	96.9	25.5	31.8	29.3	0.2	72.6	43.5	5.9	0.0	0.0	0.0
Plana (SC, RR + QRS relativos + AC)	83.6	85.4	97.4	20.4	36.4	6.6	9.8	82.8	56.8	5.1	0.0	—	0.0
Hierárquica (SC, RR + QRS relativos + AC)	88.5	89.8	97.2	22.8	38.2	22.7	0.2	74.2	43.5	4.8	0.0	0.0	0.0

Para este trabalho, escolheu-se como o melhor modelo o hierárquico com intervalos RR e duração do complexo QRS relativizados com seleção de características. Este foi o modelo hierárquico que atingiu os menores valores de  $FPR$  para todas as classes e os valores de  $Se$  são maiores para as classes de maior importância, ou seja,  $SVEB$  e  $VEB$ .

Os modelos propostos aqui por este trabalho foram incapazes de classificar batimentos da classe F, como visto nas Tabelas 5.5. Isso provavelmente se deve ao fato de a classe F ser pouco representativa (os registros 208 e 213 contém quase que a totalidade dos batimentos do tipo F) na base de dados de arritmia do MIT-BIH e a técnica para compensar o desbalanceamento aqui apresentada não foi suficiente para contornar tal problema. De acordo com Llamedo e Martínez (2011), devido à pouca representatividade dos batimentos do tipo F e também às restrições impostas pela divisão de batimentos em registros (os batimentos do tipo F estão concentrados em alguns poucos pacientes) torna-se inviável fazer uma seleção de características que encontre

boas características para discriminação de batimentos da classe F. Assim, propõem-se em (Llamedo e Martínez, 2011) uma variação do protocolo proposto pela AAMI, excluindo-se a classe Q e fusionando-se a classe F à classe VEB, criando-se a classe VEB'. A esse novo protocolo chamou-se AAMI2.

Como o trabalho aqui proposto efetua seleção de características, resolveu-se por refazer os experimentos levando-se em conta o protocolo AAMI2 (Seção 5.3), sem prejuízos ao objetivo principal deste trabalho, que é mostrar o impacto do uso de classificação hierárquica na classificação de arritmias.

Contudo, observando os valores reportados na Tabela 5.2 que avaliou os parâmetros da rede complexa para extração de características, pode-se notar que o modelo construído a partir de parâmetros da rede complexa com  $n = 6$  e  $T_Q = 0,3$  teve um melhor desempenho para a classe F, mesmo que pouco significativo. Esse fato pode indicar que o modelo inicial escolhido pode não ter características promissoras para discriminar batimentos da classe F. Entretanto, para a utilização deste método objetivando também a classificação da classe F, mais experimentos devem ser feitos a fim de se encontrar melhores características para discriminação dos batimentos pertencentes a classe F.

#### 5.2.4 Teste em DS2

Uma vez escolhido o modelo final, foi efetuado um teste com a partição DS2. Os métodos (de Chazal et al., 2004) e (Llamedo e Martínez, 2011) foram considerados por este trabalho métodos referência devido à metodologia utilizada e pelo fato de terem os melhores resultados reportados na literatura. Os resultados alcançados por este trabalho são comparáveis à (de Chazal et al., 2004) e (Llamedo e Martínez, 2011), como visto na Tabela 5.6.

Tabela 5.6: Resultado final em DS2. *FPR* não é reportado pelos outros métodos.

Método	Acc	N			SVEB			VEB			F		
		Se	+P	FPR	Se	+P	FPR	Se	+P	FPR	Se	+P	FPR
Método proposto	89,0	89,0	98,0	14,0	79,0	45,0	1,0	82,0	47,0	2,0	0,0	0,0	0,0
(de Chazal et al., 2004)	86,0	87,0	99,0	–	75,0	39,0	–	80,0	81,0	–	89,0	9,0	–
(Llamedo e Martínez, 2011)	78,0	78,0	99,0	–	76,0	41,0	–	83,0	88,0	–	95,0	4,0	–

A Tabela 5.7 apresenta o resultado final por paciente e como pode-se observar, em apenas dois registros (111 e 212) a acurácia foi inferior à 80%. Já os trabalhos tidos como referência apresentam melhores resultados para os registros 111 e 212 ( $> 90\%$ ), contudo tiveram resultado piores para os registros 202 e 222 ( $< 80\%$ ) (de Chazal et al., 2004, Tabela 7) e (Llamedo e Martínez, 2011, Tabela 5). Observe que os registros 111 e 212 são praticamente compostos por batimentos da classe normal, já os registros 202 e 222 juntos representam 14% dos batimentos da classe SVEB. Esse fato sugere que batimentos de determinados registros são mais difíceis de



Tabela 5.7: Resultado por paciente em DS2. O modelo utilizado foi o hierárquico com seleção de características independente para cada classificador.

Registro	Acc1	N			Arr			Acc2	SVEB			VEB			F		
		Se/+P/FPR			Se/+P/FPR				Se/+P/FPR			Se/+P/FPR			Se/+P/FPR		
100	99,3	99,7	99,6	26,5	73,5	78,1	0,3	100,0	100,0	100,0	0,0	100,0	100,0	0,0	0,0	0,0	0,0
103	92,6	92,6	100,0	0,0	100,0	1,3	7,4	50,0	50,0	100,0	–	–	0,0	50,0	–	–	0,0
105	86,4	86,2	100,0	2,2	97,8	11,5	13,8	28,9	–	0,0	60,0	32,5	72,2	100,0	–	–	0,0
111	30,1	30,0	100,0	0,0	100,0	0,1	70,0	100,0	–	–	0,0	100,0	100,0	–	–	–	0,0
113	96,5	96,5	100,0	0,0	100,0	8,7	3,5	66,7	66,7	100,0	–	–	0,0	33,3	–	–	0,0
117	96,4	96,4	100,0	0,0	100,0	1,8	3,6	0,0	0,0	–	–	–	0,0	100,0	–	–	0,0
121	96,0	96,0	100,0	0,0	100,0	2,6	4,0	100,0	100,0	100,0	0,0	100,0	100,0	0,0	–	–	0,0
123	99,4	99,4	100,0	0,0	100,0	25,0	0,6	100,0	–	–	0,0	100,0	100,0	–	–	–	0,0
200	91,2	90,8	95,9	7,9	92,1	83,2	9,2	94,9	28,6	6,9	3,4	95,5	99,3	71,4	–	0,0	1,0
202	95,8	96,0	99,6	10,7	89,3	45,0	4,0	61,2	46,9	100,0	0,0	100,0	41,9	51,0	–	0,0	1,5
210	97,1	98,0	98,8	12,3	87,7	80,2	2,0	85,4	54,5	41,4	9,6	90,8	92,9	48,0	0,0	–	0,0
212	41,0	41,0	100,0	–	–	0,0	59,0	–	–	–	–	–	–	–	–	–	–
213	89,8	98,5	89,8	48,2	51,8	89,0	1,5	67,7	29,2	100,0	0,0	100,0	67,0	93,6	0,0	–	0,0
214	97,3	97,1	99,9	0,4	99,6	81,4	2,9	99,2	–	–	0,0	100,0	99,2	100,0	0,0	–	0,0
219	95,5	95,9	99,5	13,9	86,1	41,9	4,1	96,8	0,0	0,0	1,6	100,0	98,4	50,0	0,0	–	0,0
221	99,1	99,0	99,9	0,5	99,5	94,9	1,0	99,7	–	0,0	0,3	99,7	100,0	–	–	–	0,0
222	82,8	83,2	97,7	21,5	78,5	30,0	16,8	96,3	96,3	100,0	–	–	0,0	3,0	–	0,0	0,6
228	96,6	96,3	99,6	1,9	98,1	85,2	3,7	95,0	100,0	15,4	3,1	94,9	100,0	0,0	–	0,0	2,0
231	99,1	99,2	99,9	33,3	66,7	13,3	0,8	100,0	–	–	0,0	100,0	100,0	–	–	–	0,0
232	89,4	97,2	68,6	12,8	87,2	99,1	2,8	95,3	95,3	100,0	–	–	0,0	4,7	–	–	0,0
233	97,2	98,3	97,8	5,8	94,2	95,5	1,7	90,4	100,0	6,2	7,7	90,4	99,9	20,0	0,0	0,0	1,9
234	97,6	99,3	98,2	92,5	7,5	18,2	0,7	100,0	100,0	100,0	0,0	100,0	100,0	0,0	–	–	0,0
Média	88,8	89,1	98,1	13,7	86,3	49,3	10,9	91,6	91,7	90,5	4,5	94,4	96,0	13,5	0,0	0,0	0,7

serem classificados, e que as características escolhidas para a construção dos modelos podem beneficiar alguns registros em detrimento de outros.

### 5.3 Protocolo AAMI2

Nesta seção, os experimentos foram refeitos a fim de se contemplar o protocolo AAMI2 proposto em (Llamedo e Martínez, 2011). De acordo com Llamedo e Martínez (2011), a diferença entre o protocolo AAMI2 para o proposto pela própria AAMI é apenas a exclusão dos batimentos da classe Q e a fusão dos batimentos da classe F à classe VEB, criando-se a nova classe VEB’.

#### 5.3.1 Modelos de Classificação para AAMI2

Com relação aos parâmetros de construção da rede complexa, optou-se por continuar com o modelo inicial obtido com  $n = 2$ ,  $T_0 = 0,05$  e  $T_Q = 0,3$ . Dessa forma, foram construídos novos modelos de classificação plana e hierárquicos com todas as 26 características. Os resultados obtidos podem ser vistos na Tabela 5.8).

Com apenas 3 classes (N, SVEB e VEB’), os pesos para contornar o problema do desbalanceamento passaram a ser diferentes. Para a classificação plana os valores dos pesos foram:  $w_1 = 1, w_2 = 50, w_3 = 10$ , que são os pesos referentes as classe N, SVEB e VEB’. Para classificação hierárquica, utilizou-se  $w_1 = 1$  e  $w_2 = 10$ , para as classes normal e arritmica, respectivamente, e para o classificador do segundo nível utilizou-se  $w_1 = 3, w_2 = 1$ , para as classes

Tabela 5.8: Desempenho dos modelos em DS1 - validação cruzada por paciente 22-folds. Protocolo AAMI2.

Tipo de classificação	Acc	N			SVEB			VEB'		
		Se	+P	FPR	Se	+P	FPR	Se	+P	FPR
Plana	77.1	78.4	97.2	20.0	31.8	3.9	14.8	72.2	48.3	6.9
Hierárquica	88.5	90.1	96.9	25.5	23.8	29.4	0.2	73.3	43.2	6.7

Tabela 5.9: Características selecionadas para 3 modelos: Modelo de classificação plana (Plano), primeiro nível hierárquico (Hierárquico 1) e segundo nível hierárquico (Hierárquico 2). Protocolo AAMI2.

Classificador	Intervalo RR		$CN(VCG(WT - A1))$ com $T_l = 0,05$					$CN(VCG(WT - A1))$ com $T_l = 0,30$				
	prev	pos	$k_\mu$	$k_{max}$	H	E	P	$k_\mu$	$k_{max}$	H	E	P
Hierárquico 1	x	x	-	-	x	-	-	-	-	x	-	-
Hierárquico 2	x	x	-	-	-	x	x	-	-	-	-	-
Plano	x	x	-	-	-	-	-	-	-	-	-	-

Classificador	$CN(VCG(WT - D1))$ com $T_l = 0,05$					$CN(VCG(WT - D1))$ com $T_l = 0,30$					var(AC(x))			largura
	$k_\mu$	$k_{max}$	H	E	P	$k_\mu$	$k_{max}$	H	E	P	D1	D2	A2	
Hierárquico 1	x	-	-	-	-	-	-	-	-	-	x	x	x	x
Hierárquico 2	-	-	-	-	-	-	-	-	-	-	x	x	x	x
Plano	x	x	-	x	x	-	-	-	-	-	x	x	x	x

SVEB e VEB' (VEB + F), respectivamente. Os pesos foram definidos proporcionalmente ao número de instâncias de cada classe devido a nova configuração da base.

Novamente, foi utilizado o algoritmo de busca para frente e análise de sensibilidade do SVM para seleção das melhores características. As características selecionadas são apresentadas na Tabela 5.9.

Para o classificador plano, o algoritmo de busca para frente e análise de sensibilidade do SVM selecionou apenas características da banda D1 ( $T_l = 0,05$ ), enquanto que para o modelo hierárquico ele tendeu a selecionar mais características provindas da banda A1. Observa-se que as características selecionadas aqui foram diferentes das características escolhidas na Seção 5.2.2.1 (Protocolo AAMI).

### 5.3.2 Melhor modelo AAMI2

Pode-se observar a partir dos resultados reportados na Tabela 5.10, que o uso do protocolo AAMI2 não altera significativamente os resultados obtidos para classes N, e SVEB usando o protocolo AAMI (Tabela 5.5). Além disso, a fusão das classes VEB e F na classe VEB'

Tabela 5.10: Desempenho dos modelos variando o conjunto de características: total (26 características) e seleção de características (SC). Protocolo AAMI2.

Tipo de classificação	Acc	N			SVEB			VEB'		
		Se	+P	FPR	Se	+P	FPR	Se	+P	FPR
Plana (26 características)	77,1	78,4	97,2	20,0	31,8	3,9	14,8	72,2	48,3	6,9
Hierárquica (26 características)	88,5	90,1	96,9	25,5	23,8	29,4	0,2	73,3	43,2	6,7
Plana (SC, RR + QRS relativos)	84,8	86,5	97,6	19,3	36,3	8,3	7,6	76,5	51,8	6,4
Hierárquica (SC, RR + QRS relativos)	88,6	89,9	97,2	22,8	34,2	32,8	0,2	75,6	43,3	5,6
	88,5	89,9	97,1	23,7	25,1	31,07	0,2	74,7	42,2	6,8

Tabela 5.11: Resultado final em DS2. Protocolo AAMI2.

Método	Acc	N			SVEB			VEB'		
		Se	+P	FPR	Se	+P	FPR	Se	+P	FPR
Método proposto	88,8	89,2	98,1	13,8	78,2	46,4	0,3	83,8	47,3	1,0
(de Chazal et al., 2004)	90,0	92,0	99,0	–	74,0	33,0	–	70,0	58,0	–
(Llamedo e Martínez, 2011)	93,0	95,0	98,0	–	77,0	39,0	–	81,0	87,0	–

não degradou a precisão do classificador para esta nova classe. Portanto, pode-se escolher o melhor modelo da mesma forma que foi feita para o protocolo AAMI. Isto é, escolheu-se como melhor modelo, aquele modelo hierárquico que atingiu os menores valores de *FPR* para todas as classes e os valores de *Se* são maiores para as classes de maior importância, ou seja, *SVEB* e *VEB*. O modelo escolhido novamente é o hierárquico com intervalos RR e duração do complexo QRS relativizados com seleção de características.

### 5.3.3 Teste com AAMI2

Visando comparar o melhor modelo obtido usando-se o protocolo AAMI2 com os métodos referências ((Llamedo e Martínez, 2011) e (de Chazal et al., 2004)), treinou-se o modelo hierárquico com seleção de características e características do intervalo RR e QRS relativizadas em DS1, e testou-se nos registros/batimentos de DS2. O resultado final obtido em DS2 (*gross*) comparando-se com os outros dois métodos pode ser visto na Tabela 5.11, e o resultado da classificação do modelo testado em DS2 por registro pode ser visto na Tabela 5.12.

De acordo com as Tabelas 5.6 e 5.11, os métodos propostos por (Llamedo e Martínez, 2011) e (de Chazal et al., 2004) obtiveram maior acurácia global quando foi usado o protocolo AAMI2, quando comparados com o reportados pelo trabalho proposto nesta dissertação. Por outro lado, o método proposto aqui reporta valores ligeiramente maiores de *Se* para as classes *SVEB* e *VEB'* usando-se o protocolo AAMI2 quando comparados com os valores obtidos pelos métodos propostos por (Llamedo e Martínez, 2011) e (de Chazal et al., 2004). Ainda, o valor de *+P* para a classe *SVEB* é superior aos obtidos pelos outros dois métodos, ao custo de se obter menor valor de *+P* para a classe *VEB'*. Salienta-se que as classes *SVEB* e *VEB* (inclusive em *VEB'*) são as mais importantes para a detecção de arritmias.

Tabela 5.12: Resultado por paciente em DS2. O modelo utilizado foi o hierárquico com seleção de características independente para cada classificador. Protocolo AAMI2

Registro	Acc1	N <i>Se/+P/FPR</i>			Arr <i>Se/+P/FPR</i>			Acc2	SVEB <i>Se/+P/FPR</i>			VEB' <i>Se/+P/FPR</i>		
100	99,3	99,7	99,6	26,5	73,5	78,1	0,3	100,0	100,0	100,0	0,0	100,0	100,0	0,0
103	92,7	92,7	100,0	0,0	100,0	1,3	7,3	50,0	50,0	100,0	–	–	0,0	50,0
105	86,4	86,2	100,0	2,4	97,6	10,3	13,8	55,0	–	0,0	45,0	55,0	100,0	–
111	30,3	30,3	100,0	0,0	100,0	0,1	69,7	100,0	–	–	0,0	100,0	100,0	–
113	96,6	96,6	100,0	0,0	100,0	9,0	3,4	50,0	50,0	100,0	–	–	0,0	50,0
117	96,6	96,6	100,0	0,0	100,0	1,9	3,4	0,0	0,0	–	–	–	0,0	100,0
121	96,1	96,1	100,0	0,0	100,0	2,7	3,9	100,0	100,0	100,0	0,0	100,0	100,0	0,0
123	99,4	99,4	100,0	0,0	100,0	25,0	0,6	100,0	–	–	0,0	100,0	100,0	–
200	91,2	90,8	95,9	7,9	92,1	83,2	9,2	96,1	28,6	7,1	3,3	96,7	99,3	71,4
202	95,6	95,9	99,6	10,7	89,3	44,1	4,1	61,2	46,9	100,0	0,0	100,0	40,9	53,1
210	97,1	98,0	98,8	12,3	87,7	80,2	2,0	85,4	45,5	37,0	9,6	90,4	93,0	54,5
212	41,8	41,8	100,0	–	–	0,0	58,2	–	–	–	–	–	–	–
213	89,8	98,6	89,8	48,2	51,8	89,3	1,4	93,4	12,5	100,0	0,0	100,0	93,3	87,5
214	97,4	97,1	100,0	0,0	100,0	81,3	2,9	99,6	–	0,0	0,4	99,6	100,0	–
219	95,4	95,7	99,5	13,9	86,1	40,8	4,3	96,8	0,0	0,0	1,6	98,4	98,4	100,0
221	99,1	99,0	99,9	0,5	99,5	94,9	1,0	99,7	–	0,0	0,3	99,7	100,0	–
222	83,0	83,4	97,6	22,0	78,0	30,2	16,6	96,3	96,3	100,0	–	–	0,0	3,7
228	96,7	96,4	99,6	1,9	98,1	85,6	3,6	98,3	100,0	25,0	1,7	98,3	100,0	0,0
231	99,1	99,2	99,9	33,3	66,7	13,3	0,8	100,0	–	–	0,0	100,0	100,0	–
232	89,2	97,2	68,1	13,1	86,9	99,1	2,8	94,8	94,8	100,0	–	–	0,0	5,3
233	97,2	98,3	97,8	5,8	94,2	95,5	1,7	97,8	100,0	18,2	2,3	97,7	100,0	0,0
234	97,6	99,3	98,2	92,5	7,5	18,2	0,7	75,0	0,0	–	0,0	100,0	75,0	100,0
Gross	88,8	89,2	98,1	13,8	86,2	49,4	10,8	95,1	90,7	94,0	2,8	97,2	95,7	9,3

## Capítulo 6

# Considerações Finais

Neste trabalho, vários assuntos relacionados ao processo de classificação de batimentos cardíacos a partir do ECG foram discutidos.

No Capítulo 2, a fundamentação teórica foi apresentada. A princípio, a norma ANSI/AAMI (2008) que regulamenta a forma de avaliação de métodos de classificação de arritmias foi apresentada na Seção 2.1. Então, o banco de dados mais utilizado na literatura para classificação de arritmias e também utilizado neste trabalho foi descrito na Seção 2.2. Também analisaram-se os resultados de alguns métodos para classificação automática de arritmias publicados na literatura. Na Seção 2.3, foram discutidos os resultados apresentados em (Luz e Menotti, 2011a), em que alguns métodos foram re-implementados para se adequar ao esquema de seleção de registros proposto em (de Chazal et al., 2004) e as recomendações da AAMI. Concluiu-se que a escolha dos batimentos cardíacos para se construir o classificador e também para avaliá-lo impacta fortemente os resultados. Isto é, caso a seleção dos batimentos seja enviesada (sem tomar o cuidado de separar batimentos de um mesmo paciente para teste e treinamento), o desempenho do classificador é fortemente influenciado de forma positiva, levando a uma falsa crença de alta confiabilidade do sistema construído a partir destes classificadores.

Pode-se perceber que poucos autores estão preocupados em utilizar um protocolo padrão para avaliação dos métodos, o que dificulta a comparação entre eles e, ainda, a prática de se incluir batimentos de um mesmo paciente tanto no conjunto de teste quanto no de treino não está sendo evitada, mesmo depois de vários trabalhos na literatura (de Chazal et al., 2004; Ince et al., 2009; Llamedo e Martínez, 2011; Luz e Menotti, 2011a) chamarem atenção para este fato.

Assim, reitera-se que a escolha dos batimentos para se construir os classificadores e avaliar os mesmos deve ser feita conforme a norma AAMI e que a prática de se colocar batimentos de um mesmo paciente no conjunto de treino e de teste deve ser evitada, para que os resultados tenham validade do ponto de vista clínico.

O Capítulo 3 foi dedicado a uma revisão da literatura sobre todos os passos que envolvem

o desenvolvimento de um sistema de classificação de batimentos cardíacos a partir do ECG. Nele, foram apontadas diversas oportunidades de trabalhos futuros.

No capítulo 4, foi proposto um novo método usando classificação hierárquica com o algoritmo de aprendizado de máquina SVM, extração de características baseado em redes complexas a partir do VCG (representação bidimensional a partir de duas derivações) e seleção de características. A avaliação do método foi feita conforme recomendações da AAMI e utilizou-se o banco de dados de arritmia do MIT-BIH. Os resultados obtidos com classificação hierárquica são comparáveis aos resultados publicados em (de Chazal et al., 2004) e (Llamedo e Martínez, 2011), *i.e.*, *Se* de 79,1%, *+P* de 45,2% e *FPR* de 0,5% para a classe SVEB e *Se* de 81,5%, *+P* de 47,3% e *FPR* de 1,5% para a classe VEB (ver Tabela 5.6), e os ganhos reportados aqui, para as classes SVEB e N, são significativos, considerando-se o protocolo AAMI. Acredita-se que os resultados poderiam ser melhores, se todos os registros do banco de dados tivessem as mesmas derivações A e B.

As novas características propostas por este trabalho mostraram-se eficientes, mesmo para o caso de classificação plana, sugerindo que características extraídas usando-se o VCG modelado por redes complexas podem ser melhor exploradas futuramente por outros trabalhos.

Também ressaltam-se as vantagens da classificação hierárquica com relação à classificação plana, já que resultados obtidos com classificação hierárquica se mostraram mais imunes a falsos positivos, obtiveram melhores valores em *+P* e não houve perdas significativas em *Se*.

Os resultados apresentados nas Tabelas 5.3 e 5.5 sugerem que a seleção de características por meio de busca para frente e análise de sensibilidade do SVM conseguiu aprimorar o desempenho do modelo, aumentando o poder de generalização dos modelos, em especial para classificação plana. Entretanto, outros métodos mais sofisticados podem resultar em uma seleção que apresente um maior desempenho e este ponto também pode ser explorado em trabalhos futuros.

Também deve ser destacado a discrepância entre os resultados conseguidos com o modelo final para treino e teste (ver Tabelas 5.3 e 5.6), como já citado em (Llamedo e Martínez, 2011), o que reforça o fato de que existe problemas com as partições DS1 e DS2 propostas por de Chazal et al. (2004). Aparentemente, DS1 possui batimentos mais difíceis de serem classificados. A publicação de resultados considerando-se apenas o esquema de divisão proposto por de Chazal et al. (2004) também pode levar autores a se especializarem em DS2.

Novas pesquisas podem ser feitas, visando a criação de novos protocolos de testes, assim como novas partições para avaliação de classificadores, de forma a se conseguir resultados mais consistentes e mais próximos do que se espera encontrar em um ambiente clínico.

Muitas pesquisas estão sendo feitas visando classificação de arritmias em sinais de ECG e diversos autores têm publicado resultados promissores. Todavia, existe muita margem para melhoras e conseqüentemente mais pesquisas sobre o assunto devem ser feitas. Com este trabalho, procurou-se contribuir com a literatura utilizando técnicas ainda não exploradas,

---

novas características e apontaram-se alguns trabalhos futuros. Entre os diversos relacionados, destaca-se aquele de reimplantação e de análise de métodos propostos na literatura que não seguiram um esquema de seleção de batimentos sem enviesamento.

# Referências Bibliográficas

- Acharya, U. R.; Bhat, P. S.; Iyengar, S.; Rao, A. e Dua, S. (2003). Classification of heart rate data using artificial neural network and fuzzy equivalence relation. *Pattern Recognition*, 36(1):61–68.
- Addison, P. S. (2005). Wavelet transforms and the ECG: a review. *Physiological Measurement*, 26(5):155–199.
- Afonso, V. X.; Tompkins, W. J.; Nguyen, T. Q. e Luo, S. (1999). ECG beat detection using filter banks. *IEEE Transactions on Biomedical Engineering*, 46(2):192–202.
- American Heart Association (1998). AHA database. disponível em: <http://www.ahadata.com/>. último acesso em 01/02/2012.
- Andreaeo, R.; Dorizzi, B. e Boudy, J. (2006). ECG signal analysis through hidden markov models. *IEEE Transactions on Biomedical Engineering*, 53(8):1541–1549.
- ANSI/AAMI (2008). Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms. American National Standards Institute, Inc. (ANSI), Association for the Advancement of Medical Instrumentation (AAMI). ANSI/AAMI/ISO EC57, 1998-(R)2008.
- Antiqueira, L.; Nunes, M. G. V.; Oliveira, O. N. e Costa, L. F. (2007). Strong correlations between text quality and complex networks features. *Physica A*, 373(1):811–820.
- Asl, B. M.; Setarehdan, S. K. e Mohebbi, M. (2008). Support vector machine-based arrhythmia classification using reduced features of heart rate variability signal. *Artificial Intelligence in Medicine*, 44(1):51–64.
- Backes, A. R.; Casanova, D. e Bruno, O. M. (2009). A complex network-based approach for boundary shape analysis. *Pattern Recognition*, 42(1):54–67.
- Bahoura, M.; Hassani, M. e Hubin, M. (2007). DSP implementation of wavelet transform for real time ECG wave forms detection and heart rate analysis. *Computer Methods and Programs in Biomedicine*, 52(1):35–44.



- Barros, A. K.; Mansour, A. e Ohnishi, N. (1998). Removing artifacts from electrocardiographic signals using independent components analysis. *Neurocomputing*, 22(1-3):173–186.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, 1 edição.
- Bortolan, G.; Christov, I. e Pedrycz, W. (2007). Hyperbox classifiers for ECG beat analysis. In *Computers in Cardiology*, volume 34, pp. 145–148.
- Castells, F.; Laguna, P.; Sörnmo, L.; Bollmann, A. e Roig, J. M. (2007). Principal component analysis in ECG signal processing. *EURASIP Journal on Applied Signal Processing*, 2007(1):98–98.
- Celler, B. e de Chazal, P. (1997). Selection of parameters from power spectral density, wavelet transforms and other methods for the automated interpretation of the ECG. In *IEEE International Conference on Digital Signal Processing (ICDSP)*, pp. 1–4.
- Ceylan, R.; Özbay, Y. e Karlik, B. (2009). A novel approach for classification of ECG arrhythmias: Type-2 fuzzy clustering neural network. *Expert Systems with Applications*, 36(3):6721–6726.
- Ceylanand, R. e Özbay, Y. (2007). Comparison of FCM, PCA and WT techniques for classification ECG arrhythmias using artificial neural network. *Expert Systems with Applications*, 33(2):286–295.
- Chalumeau, T.; Costa, L. F.; Laligant, O. e Meriaudeau, F. (2006). Texture discrimination using hierarchical complex networks. In *International Conference on Signal-Image Technology and Internet-Based Systems*, pp. 543–550.
- Chang, C.-C. e Lin, C.-J. (2011). LIBSVM: A library for support vector machines. *ACM Transactions on Intelligent Systems and Technology*, 2(3):27:1–27:27. software disponível em: <http://www.csie.ntu.edu.tw/~cjlin/libsvm>, último acesso em 01/02/2012.
- Chawla, M. (2009). A comparative analysis of principal component and independent component techniques for electrocardiograms. *Neural Computing and Applications*, 18(6):539–556.
- Chawla, N. V.; Bowyer, K. W. e Kegelmeyer, W. P. (2002). Smote: Synthetic minority over-sampling technique. *Journal Of Artificial Intelligence Research*, 16(1):321 – 357.
- Christov, I. e Bortolan, G. (2004). Ranking of pattern recognition parameters for premature ventricular contractions classification by neural networks. *Physiological Measurement*, 25(5):1281–1290.
- Chua, K. C.; Chandran, V.; Acharya, U. R. e Lim, C. M. (2009). Higher order spectra based support vector machine for arrhythmia classification. In *International Conference on Biomedical Engineering (ICBME)*, pp. 231–234.

- Clarkson, P.; Chen, S.-W. e Fan, Q. (1995). A robust sequential detection algorithm for cardiac arrhythmia classification. In *International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, volume 2, pp. 1181–1184.
- Clifford, G. D.; Azuaje, F. e McSharry, P. (2006). *Advanced Methods And Tools for ECG Data Analysis*. Artech House Publishers, 1 edição.
- Coast, D.; Stern, R.; Cano, G. e Briller, S. (1990). An approach to cardiac arrhythmia analysis using hidden markov models. *IEEE Transactions on Biomedical Engineering*, 37(9):826–836.
- Cohen, A. (1988). *Biomedical Signal Processing*. CRC Press.
- Cortes, C. e Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.
- Costa, E.; Lorena, A.; Carvalho, A. e Freitas, A. (2008). Top-down hierarchical ensembles of classifiers for predicting g-protein-coupled-receptor functions. In *Advances in Bioinformatics and Computational Biology*, volume 5167 of *Lecture Notes in Computer Science*, pp. 35–46. Springer Berlin / Heidelberg.
- de Chazal, P.; O'Dwyer, M. e Reilly, R. B. (2004). Automatic classification of heartbeats using ECG morphology and heartbeat interval features. *IEEE Transactions on Biomedical Engineering*, 51(7):1196–1206.
- de Chazal, P. e Reilly, R. B. (2006). A patient-adapting heartbeat classifier using ECG morphology and heartbeat interval features. *IEEE Transactions on Biomedical Engineering*, 53(12):2535–2543.
- de Lannoy, G.; François, D.; Delbeke, J. e Verleysen, M. (2010). Weighted svms and feature relevance assessment in supervised heart beat classification. In *Biomedical Engineering Systems and Technologies (BIOSTEC)*, pp. 212–223.
- Dokur, Z. e Ölmez, T. (2001). ECG beat classification by a novel hybrid neural network. *Computer Methods and Programs in Biomedicine*, 66(2-3):167–181.
- Duda, R. O.; Hart, P. E. e Stork, D. G. (2000). *Pattern Classification*. Wiley-Interscience, 2nd. ed edição.
- Exarchos, T.; Tsipouras, M.; Nanou, D.; Bazios, C.; Antoniou, Y. e Fotiadis, D. (2005). A platform for wide scale integration and visual representation of medical intelligence in cardiology: the decision support framework. In *Computers in Cardiology*, volume 32, pp. 167–170.

- Exarchos, T. P.; Tsipouras, M. G.; Exarchos, C. P.; Papaloukas, C.; Fotiadis, D. I. e Michalis, L. K. (2007). A methodology for the automated creation of fuzzy expert systems for ischemic and arrhythmic beat classification based on a set of rules obtained by a decision tree. *Artificial Intelligence in Medicine*, 40(3):187–200.
- Ferrara, E. R. e Widrow, B. (1982). Fetal electrocardiogram enhancement by time-sequenced adaptive filtering. *IEEE Transactions on Biomedical Engineering*, 29(6):458–460.
- Gao, D.; Madden, M.; Chambers, D. e Lyons, G. (2005). Bayesian ANN classifier for ECG arrhythmia diagnostic system: a comparison study. In *IEEE International Joint Conference on Neural Networks (IJCNN)*, volume 4, pp. 2383–2388.
- Goldberger, A. L.; Amaral, L. A. N.; Glass, L.; Hausdorff, J. M.; Ivanov, P. C.; Mark, R. G.; Mietus, J. E.; Moody, G. B.; Peng, C.-K. e Stanley, H. E. (2000). Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23):215–220. base de dados e ferramentas disponíveis em: <http://www.physionet.org/>, último acesso em 01/02/2012.
- Gomes, P. R.; Soares, F. O.; Correia, J. H. e Lima, C. S. (2010). ECG data-acquisition and classification system by using wavelet-domain hidden markov models. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 4670–4673.
- Güler, I. e Übeyli, E. D. (2005). ECG beat classifier designed by combined neural network model. *Pattern Recognition*, 38(2):199–208.
- Gutiérrez, E. C. J. M. e Hadi, A. (1997). Sensitivity analysis in discrete bayesian networks. *IEEE Transactions on Systems, Man and Cybernetics*, 26(7):412–423.
- Guyon, I. e Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182.
- Ham, F. M. e Han, S. (1996). Classification of cardiac arrhythmias using fuzzy artmap. *IEEE Transactions on Biomedical Engineering*, 43(4):425–429.
- Hamilton, P. (2002). Open source ECG analysis. In *Computers in Cardiology*, volume 29, pp. 101–104.
- Hamilton, P. S. e Tompkins, W. J. (1986). Quantitative investigation of QRS detection rules using the mit/bih arrhythmia database. *IEEE Transactions on Biomedical Engineering*, 33(12):1157–1165.
- He, T.; Clifford, G. e Tarassenko, L. (2006). Application of independent component analysis in removing artefacts from the electrocardiogram. *Neural Computing and Applications*, 15(2):105–116.

- Holden, N. e Freitas, A. A. (2008). Improving the performance of hierarchical classification with swarm intelligence. In *European Conference on Evolutionary Computation, Machine Learning and Data Mining in Bioinformatics (EvoBIO)*, pp. 48–60.
- Hu, Y. H.; Palreddy, S. e Tompkins, W. J. (1997). A patient-adaptable ECG beat classifier using a mixture of experts approach. *IEEE Transactions on Biomedical Engineering*, 44(9):891–900.
- Hu, Y. H.; Tompkins, W. J.; Urrusti, J. L. e Afonso, V. X. (1990). Application of artificial neural networks for ECG signal detection and classification. *Journal of Eletrocardiology*, 26(supplement):66–73.
- Huang, H.; Hu, G. e LiZhu (2010). Ensemble of support vector machines for heartbeat classification. In *IEEE International Conference on Signal Processing (ICSP)*, pp. 1327–1330.
- Ince, T.; Kiranyaz, S. e Gabbouj, M. (2009). A generic and robust system for automated patient-specific classification of ECG signals. *IEEE Transactions on Biomedical Engineering*, 56(5):1415–1427.
- Jiang, W. e Kong, G. S. (2007). Block-based neural networks for personalized ECG signal classification. *IEEE Transactions on Neural Networks*, 18(6):750–761.
- Jung, Y. e Tompkins, W. J. (2003). Detecting and classifying life-threatening ECG ventricular arrhythmias using wavelet decomposition. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, volume 3, pp. 2390–2393.
- Kadambe, S.; Murray, R. e Boudreaux-Bartels, G. F. (1999). Wavelet transform-based QRS complex detector. *IEEE Transactions on Biomedical Engineering*, 46(7):838–848.
- Karimifard, S.; Ahmadian, A.; Khoshnevisan, M. e Nambakhsh, M. S. (2006). Morphological heart arrhythmia detection using hermitian basis functions and kNN classifier. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 1367–1370.
- Kernel Machines (2012). Reproduce easy.py of LIBSVM in MATLAB. disponível em: <http://agbs.kyb.tuebingen.mpg.de/km/bb/showthread.php?tid=1018&highlight=easy+libsvm+multiple+class>. último acesso em 01/02/2012.
- Khorrani, H. e Moavenian, M. (2010). A comparative study of DWT, CWT and DCT transformations in ECG arrhythmias classification. *Expert Systems with Applications*, 37(8):5751–5757.

- Kim, H.; Yazicioglu, R. F.; Merken, P.; van Hoof, C. e Yoo, H.-J. (2010). ECG signal compression and classification algorithm with quad level vector for ECG holter system. *IEEE Transactions on Information Technology in Biomedicine*, 14(1):93–100.
- Kim, J.; Shin, H. S.; Shin, J. e Lee, M. (2009). Robust algorithm for arrhythmia classification in ECG using extreme learning machine. *BioMedical Engineering OnLine*, 8(1):1–12.
- Kohler, B.-U.; Hennig, C. e Orglmeister, R. (2002). The principles of *software* QRS detection. *IEEE Engineering in Medicine and Biology Magazine*, 21(1):42–57.
- Korürek, M. e Doğan, B. (2010). ECG beat classification using particle swarm optimization and radial basis function neural network. *Expert Systems with Applications*, 37(12):7563–7569.
- Korürek, M. e Nizam, A. (2008). A new arrhythmia clustering technique based on ant colony optimization. *Journal of Biomedical Informatics*, 41(6):874–881.
- Lagerholm, M.; Peterson, C.; Braccini, G.; Edenbrandt, L. e Sörnmo, L. (2000). Clustering ECG complexes using hermite functions and self-organizing maps. *IEEE Transactions on Biomedical Engineering*, 47(7):838–848.
- Laguna, P.; Jané, R. e Caminal, P. (1994). Automatic detection of wave boundaries in multi-lead ECG signals: Validation with the CSE database. *Computers and Biomedical Research*, 27(1):45–60.
- Lanató, A.; Valenza, G.; Mancuso, C. e Scilingo, E. P. (2011). Robust multiple cardiac arrhythmia detection through bispectrum analysis. *Expert Systems with Applications*, 38(6):6798–6804.
- Lee, J.; Jeong, K.; Yoon, J. e Lee, M. (1996). A simple real-time QRS detection algorithm. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, volume 4, pp. 1396–1398.
- Lee, J.; Park, K. L.; Song, M. H. e Lee, K. J. (2005). Arrhythmia classification with reduced features by linear discriminant analysis. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 1142–1144.
- Li, C.; Zheng, C. e Tai, C. (1995). Detection of ECG characteristic points using wavelet transforms. *IEEE Transactions on Biomedical Engineering*, 42(1):21–28.
- Lin, C.; Du, Y. e Chen, T. (2008a). Adaptive wavelet network for multiple cardiac arrhythmias recognition. *Expert Systems with Applications*, 34(4):2601–2611.

- Lin, C.-H.; Chen, P.-J.; Chen, Y.-F.; Lee, Y.-Y. e Chen, T. (2005). Multiple cardiac arrhythmia recognition using adaptive wavelet network. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 5655–5659.
- Lin, S.-W.; Ying, K.-C.; Chen, S.-C. e Lee, Z.-J. (2008b). Particle swarm optimization for parameter determination and feature selection of support vector machines. *Expert Systems with Applications*, 35(4):1817 – 1824.
- Llamedo, M. e Martínez, J. P. (2011). Heartbeat classification using feature selection driven by database generalization criteria. *IEEE Transactions on Biomedical Engineering*, 58(3):616–625.
- Luz, E. e Menotti, D. (2011a). How the choice of samples for building arrhythmia classifiers impact their performances. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 4988–4991.
- Luz, E. e Menotti, D. (2011b). An x-ray on methods aiming at arrhythmia classification in ECG signals. In *Internacional Conference on Bioinformatics and Computational Biology (BIOCOMP) / World Congress in Computer Science (WORLDCOMP)*, pp. 1–6.
- Lynn, P. (1979). Recursive digital filters for biological signals. *Medical and Biological Engineering and Computing*, 9(1):37–43.
- Mahesh, V.; Kandaswamy, A.; Vimal, C. e Sathish, B. (2009). ECG arrhythmia classification based on logistic model tree. *Journal of Biomedical Science and Engineering*, 2(6):405–411.
- Mar, T.; Zaunseder, S.; Martínez, J.; Llamedo, M. e Poll, R. (2011). Optimization of ECG classification by means of feature selection. *IEEE Transactions on Biomedical Engineering*, 58(8):2168–2177.
- Martinez, J.; Almeida, R.; Olmos, S.; Rocha, A. e Laguna, P. (2004). A wavelet-based ECG delineator: evaluation on standard databases. *IEEE Transactions on Biomedical Engineering*, 51(4):570–581.
- Massachusetts Institute of Technology (2011). MIT-BIH ECG database. disponível em: <http://ecg.mit.edu/>. último acesso em 01/02/2012.
- McCulloch, W. S. e Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biology*, 5(4):115–133.
- Mehmet, E. (2004). ECG beat classification using neuro-fuzzy network. *Pattern Recognition Letters*, 25(15):1715–1722.

- Minami, K.; Nakajima, H. e Toyoshima, T. (1999). Real-time discrimination of ventricular tachyarrhythmia with fourier-transform neural network. *IEEE Transactions on Biomedical Engineering*, 46(2):179–185.
- Minhas, F. A. e Arif, M. (2008). Robust electrocardiogram (ECG) beat classification using discrete wavelet transform. *Physiological Measurement*, 29(5):555–570.
- Mishra, A. K. e Raghav, S. (2010). Local fractal dimension based ECG arrhythmia classification. *Biomedical Signal Processing and Control*, 5(2):114–123.
- Moavenian, M. e Khorrami, H. (2010). A qualitative comparison of artificial neural networks and support vector machines in ECG arrhythmias classification. *Expert Systems with Applications*, 37(4):3088–3093.
- Moody, G. B. e Mark, R. G. (1982). Development and evaluation of a 2-lead ECG analysis program. In *Computers in Cardiology*, volume 9, pp. 39–44.
- Moody, G. B. e Mark, R. G. (2001). The impact of the MIT-BIH arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3):45–50.
- Moraes, J. C. T. B.; Freitas, M. M.; Vilani, F. N. e Costa, E. V. (2002). A QRS complex detection algorithm using electrocardiogram leads. In *Computers in Cardiology*, volume 29, pp. 205–208.
- Nasiri, J. A.; Naghibzadeh, M.; Yazdi, H. S. e Naghibzadeh, B. (2009). ECG arrhythmia classification with support vector machines and genetic algorithm. In *IEEE European Symposium on Computer Modeling and Simulation (EMS)*, pp. 187–192.
- Neto, A. B.; Nievola, J. C.; Figueredo, M. V. M. e Rogal Jr., S. R. (2010). Automatic detection of cardiac arrhythmias using wavelets, neural networks and particle swarm optimization. In *IEEE International Conference on Industrial Technology (ICIT)*, pp. 194–198.
- Oh, I.-S.; Lee, J.-S. e Moon, B.-R. (2004). Hybrid genetic algorithms for feature selection. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 26(11):1424–1437.
- Osowski, S. e Hoai, L. T. (2004). Analysis of features for efficient ECG signal classification using neuro-fuzzy network. In *IEEE International Joint Conference on Neural Networks (IJCNN)*, volume 3, pp. 2443–2448.
- Osowski, S.; Hoai, L. T. e Markiewicz, T. (2004). Support vector machine-based expert system for reliable heartbeat recognition. *IEEE Transactions on Biomedical Engineering*, 51(4):582–589.
- Osowski, S. e Linh, T. H. (2001). ECG beat recognition using fuzzy hybrid neural network. *IEEE Transactions on Biomedical Engineering*, 48(11):1265–1271.

- Osowski, S.; Markiewicz, T. e Hoai, L. T. (2008). Recognition and classification system of arrhythmia using ensemble of neural networks. *Measurement*, 41(6):610–617.
- Owis, M.; Abou-Zied, A.; Youssef, A.-B. e Kadah, Y. (2002). Study of features based on nonlinear dynamical modeling in ECG arrhythmia detection and classification. *IEEE Transactions on Biomedical Engineering*, 49(7):733–736.
- Özbay, Y.; Ceylan, R. e Karlik, B. (2011). Integration of type-2 fuzzy clustering and wavelet transform in a neural network based ECG classifier. *Expert Systems with Applications*, 38(1):1004–1010.
- Özbay, Y. e Tezel, G. (2010). A new method for classification of ECG arrhythmias using neural network with adaptive activation function. *Digital Signal Processing*, 20(4):1040–1049.
- Özbaya, Y.; Ceylan, R. e Karlik, B. (2006). A fuzzy clustering neural network architecture for classification of ECG arrhythmias. *Computers in Biology and Medicine*, 36(4):376–388.
- Özcan, N. e Gurgen, F. (2010). Fuzzy support vector machines for ECG arrhythmia detection. In *IEEE International Conference on Pattern Recognition (ICPR)*, pp. 2973–2976.
- Pan, J. e Tompkins, W. J. (1985). A real-time QRS detection algorithm. *IEEE Transactions on Biomedical Engineering*, 32(3):230–236.
- Park, K.; Cho, B.; Lee, D.; Song, S.; Lee, J.; Chee, Y.; Kim, I. e Kim, S. (2008). Hierarchical support vector machine based heartbeat classification using higher order statistics and hermite basis function. In *Computers in Cardiology*, volume 35, pp. 229–232.
- Parlitz, U.; Berg, S.; Luther, S.; Schirdewan, A.; Kurths, J. e Wessel, N. (2011). Classifying cardiac biosignals using ordinal pattern statistics and symbolic dynamics. *Computers in Biology and Medicine*, 42(3):319–327.
- Pasolli, E. e Melgani, F. (2010). Active learning methods for electrocardiographic signal classification. *IEEE Transactions on Information Technology in Biomedicine*, 14(6):1405–1416.
- Polat, K.; Akdemir, B. e Güneş, S. (2008). Computer aided diagnosis of ECG data on the least square support vector machine. *Digital Signal Processing*, 18(1):25–32.
- Polat, K. e Güneş, S. (2007). Detection of ECG arrhythmia using a differential expert system approach based on principal component analysis and least square support vector machine. *Applied Mathematics and Computation*, 186(1):898–906.
- Poli, R.; Cagnoni, S. e Valli, G. (1995a). Genetic design of optimum linear and nonlinear QRS detectors. *IEEE Transactions on Biomedical Engineering*, 42(11):1137–1141.



- Poli, R.; Cagnoni, S. e Valli, G. (1995b). Genetic design of optimum linear and nonlinear QRS detectors. *IEEE Transactions on Biomedical Engineering*, 42(11):1137–1141.
- Pudil, P.; Novovicova, J. e Kittler, J. (1994). Floating search methods in feature selection. *Pattern Recognition Letters*, 15(11):1119–1125.
- Rodriguez, J.; Goni, A. e Illarramendi, A. (2005). Real-time classification of ECGs on a PDA. *IEEE Transactions on Information Technology in Biomedicine*, 9(1):23–34.
- Sahambi, J.; Tandon, S. e Bhatt, R. (1997). DSP based ST-segment analysis: the wavelet approach. In *Southern Biomedical Engineering Conference*, pp. 455–457.
- Sameni, R.; Shamsollahi, M. B.; Jutten, C. e Clifford, G. D. (2007). A nonlinear Bayesian filtering framework for ECG denoising. *IEEE Transactions on Biomedical Engineering*, 54(12):2172–2185.
- Sayadi, O. e Shamsollahi, M. B. (2007). Multiadaptive bionic wavelet transform: Application to ECG denoising and baseline wandering reduction. *EURASIP Journal on Advances in Signal Processing*, 2007(14):1–11.
- Sayadi, O. e Shamsollahi, M. B. (2008). ECG denoising and compression using a modified extended kalman filter structure. *IEEE Transactions on Biomedical Engineering*, 55(9):2240–2248.
- Sayadi, O. e Shamsollahi, M. B. (2009). A model-based bayesian framework for ECG beat segmentation. *Physiological Measurement*, 30(3):335–352.
- Scholkopf, B. e Smola, A. J. (2002). *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. The MIT Press.
- Shen, K.-Q.; Ong, C.-J.; Li, X.-P. e Wilder-Smith, E. P. (2008). Feature selection via sensitivity analysis of SVM probabilistic outputs. *Machine Learning*, 70(1):1–20.
- Silla Jr., C. N. e Freitas, A. A. (2011). A survey of hierarchical classification across different application domains. *Data Mining Knowledge Discovery*, 22(1-2):22–31.
- Singh, B. N. e Tiwari, A. K. (2006). Optimal selection of wavelet basis function applied to ECG signal denoising. *Digital Signal Processing*, 16(3):275–287.
- Song, M. H.; Lee, J.; Cho, S. P.; Lee, K. J. e Yoo, S. K. (2005). Support vector machine based arrhythmia classification using reduced features. *International Journal of Control, Automation, and Systems*, 3(4):509–654.
- Soria, M. e Martinez, J. (2009). Analysis of multidomain features for ECG classification. In *Computers in Cardiology*, volume 36, pp. 561–564.

- Souza, T. L. G.; Mapa, E. S.; dos Santos, K. e Menotti, D. (2011). Application of complex networks for automatic classification of damaging agents in soybean leaflets. In *IEEE International Conference of Image Processing (ICIP)*, pp. 1089–1092.
- Sufi, F. e Khalil, I. (2011). Diagnosis of cardiovascular abnormalities from compressed ECG: A data mining-based approach. *IEEE Transactions on Information Technology in Biomedicine*, 15(1):33–39.
- Sufi, F.; Mahmood, A. e Khalil, I. (2009). Diagnosis of cardiovascular abnormalities from compressed ECG: A data mining based approach. In *International Conference on Information Technology and Applications in Biomedicine (ITAB)*, pp. 1–4.
- Tavakoli, V.; Sahba, N. e Hajebi, N. (2009). A fast and accurate method for arrhythmia detection. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 1897–1900.
- Thakor, N. V. e Zhu, Y.-S. (1991). Applications of adaptive filtering to ECG analysis: noise cancellation and arrhythmia detection. *IEEE Transactions on Biomedical Engineering*, 38(8):785–794.
- Theodoridis, S. e Koutroumbas, K. (2009). *Pattern Recognition*. Elsevier, 4 edição. ISBN: 978-59749-272-0.
- Tsipouras, M.; Fotiadis, D. e Sideris, D. (2002). Arrhythmia classification using the rr-interval duration signal. In *Computers in Cardiology*, volume 29, pp. 485–488.
- Tsipouras, M. G.; Voglis, C. e Fotiadis, D. I. (2007). A framework for fuzzy expert system creation-application to cardiovascular diseases. *IEEE Transactions on Biomedical Engineering*, 54(11):2089–2105.
- Übeyli, E. D. (2007). ECG beats classification using multiclass support vector machines with error correcting output codes. *Digital Signal Processing*, 17(3):675–684.
- Übeyli, E. D. (2009). Combining recurrent neural networks with eigenvector methods for classification of ECG beats. *Digital Signal Processing*, 19(2):320–329.
- van Bommel, J. H. e Williams, J. L. (1990). Standardisation and validation of medical decision support systems: The CSE project. *Methods of Information in Medicine*, 29(4):261–262.
- Wang, X.; Yang, J.; Teng, X.; Xia, W. e Jensen, R. (2007). Feature selection based on rough sets and particle swarm optimization. *Pattern Recognition Letters*, 28(4):459 – 471.
- Watts, D. J. e Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393(6684):440–442.

- Wen, C.; Lin, T.-C.; Chang, K.-C. e Huang, C.-H. (2009). Classification of ECG complexes using self-organizing cmac. *Measurement*, 42(3):399–407.
- World Health Organization (2012). Cardiovascular disease. disponível em: [http://www.who.int/cardiovascular\\_diseases/en/](http://www.who.int/cardiovascular_diseases/en/). último acesso em 01/02/2012.
- Xue, Q.; Hu, Y. H. e Tompkins, W. J. (1992). Neural-network-based adaptive matched filtering for QRS detection. *IEEE Transactions on Biomedical Engineering*, 39(4):317–329.
- Yang, J. e Honavar, V. (1998). Feature subset selection using a genetic algorithm. *Intelligent Systems and their Applications, IEEE*, 13(2):44–49.
- Ye, C.; Coimbra, M. T. e Kumar, B. V. K. V. (2010). Arrhythmia detection and classification using morphological and dynamic features of ECG signals. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 1918–1921.
- Yeh, Y.-C.; Chiou, C. W. e Lin, H.-J. (2012). Analyzing ECG for cardiac arrhythmia using cluster analysis. *Expert Systems with Applications*, 39(1):1000–1010.
- Yelderman, M.; Widrow, B.; Cioffi, J. M.; Hesler, E. e Leddy, J. A. (1983). ECG enhancement by adaptive cancellation of electrosurgical interference. *IEEE Transactions on Biomedical Engineering*, 30(7):392–398.
- Yu, S. e Chen, Y. (2007). Electrocardiogram beat classification based on wavelet transformation and probabilistic neural network. *Pattern Recognition Letters*, 28(10):1142–1150.
- Yu, S. e Chou, K. (2008). Integration of independent component analysis and neural networks for ECG beat classification. *Expert Systems with Applications*, 34(4):2841–2846.
- Yu, S.-N. e Chou, K.-T. (2009). Selection of significant independent components for ECG beat classification. *Expert Systems with Applications*, 36(2, Part 1):2088–2096.